UNIVERZITET U SARAJEVU
ELEKTROTEHNIČKI FAKULTET
ODSJEK ZA RAČUNARSTVO I INFORMATIKU

SVD faktorizacija i primjena na kompresiju slike

ZAVRŠNI RAD

- PRVI CIKLUS STUDIJA -

Student:
Amina Alagić

Mentor:
Red. prof. dr Željko Jurić

Sarajevo,
juli 2021.

Sažetak

Svrha ovog rada je pokazati kako se faktorizacija pomoću singularnih vrijednosti (SVD) može koristiti za kompresiju slike. Bit će prikazani osnovni pojmovi o SVD, kao i metode za njeno izračunavanje. SVD faktorizira matricu slike u proizvod tri matrice. Da bi se ostvarila ušteda memorije potrebne za pohranu slike, moguće je čuvati samo elemente ove tri matrice koji sadrže najvažnije informacije o originalnoj slici.

Ključne riječi: faktorizacija pomoću singularnih vrijednosti, kompresija slike

Abstract

The purpose of this paper is to show how singular value decomposition (SVD) can be applied to image compression. The concept of SVD along with its methods for computation will be introduced. SVD decomposes image matrix into three matrices. In order to reduce storage space needed to store the image, we can keep only certain elements of those matrices while preserving the most important features of the original image.

Keywords: singular value decomposition, image compression

Elektrotehnički fakultet, Univerzitet u Sarajevu
Odsjek za računarstvo i informatiku
Red. prof. dr Željko Jurić
Sarajevo, ...(datum)

Postavka zadatka završnog rada I ciklusa:
SVD faktorizacija i primjena na kompresiju slike

U okviru rada je potrebno razviti LaTeX predložak za izradu završnog rada prvog ciklusa studija. U radu je potrebno:

- objasniti opći postupak za izradu i pisanje završnih radova prvog ciklusa studija, poštivajući odgovarajuće Pravilnike,
- dati kratko uputstvo za korištenje .tex dokumenata, pisanje slika, tabela i relacija, generisanje sadržaja, popisa slika i tabela i sl.
- dati kratko upusto za generiranje odgovarajućih .pdf dokumenata iz odgovarajućih .tex fajlova,

Preporučuje se korištenje TexLive LaTeX podrške, verzije 2013 ili novije.

Napomena: U dijelu "Postavka" se stavlja postavka rada koju je specificirao mentor prilikom davanja teme. Naročito obratiti pažnju na naslov rada koji mora biti konzistentan tokom cijelog dokumenta, i usaglašen sa temom upisanom u informacioni sistem (npr. Zamger). Na ovoj stranici se potpisuje mentor prije nego se radovi odnesu u studentsku službu.

Polazna literatura:

[1] Sonka, M., Hlavec, V., Boyle, R., "Image Processing, Analysis, and Machine Vision", Thomson, 2008.

[2] Lee, E.A., Varaiya, P., "Structure and Interpretation of Signals and Systems", Electrical Engineering & Computer Science University of California, Berkeley, 2000

Red. prof. dr Željko Jurić

Univerzitet u Sarajevu
Elektrotehnički fakultet
Odsjek za računarstvo i informatik

Izjava o autentičnosti radova

Završni rad
I ciklusa studija

Ime i prezime: Amina Alagić
Naslov rada: SVD faktorizacija i primjena na kompresiju slike
Vrsta rada: Završni rad Prvog ciklusa studija
Broj stranica: .....

Potvrđujem:

- da sam pročitao dokumente koji se odnose na plagijarizam, kako je to definirano Statutom Univerziteta u Sarajevu, Etičkim kodeksom Univerziteta u Sarajevu i pravilima studiranja koja se odnose na I i II ciklus studija, integrirani studijski program I i II ciklusa i III ciklus studija na Univerzitetu u Sarajevu, kao i uputama o plagijarizmu navedenim na web stranici Univerziteta u Sarajevu;
- da sam svjestan univerzitetskih disciplinskih pravila koja se tiču plagijarizma;
- da je rad koji predajem potpuno moj, samostalni rad, osim u dijelovima gdje je to naznačeno;
- da rad nije predat, u cjelini ili djelimično, za stjecanje zvanja na Univerzitetu u Sarajevu ili nekoj drugoj visokoškolskoj ustanovi;
- da sam jasno naznačio prisustvo citiranog ili parafraziranog materijala i da sam se referirao na sve izvore;
- da sam dosljedno naveo korištene i citirane izvore ili bibliografiju po nekom od preporučenih stilova citiranja, sa navođenjem potpune reference koja obuhvata potpuni bibliografski opis korištenog i citiranog izvora;
- da sam odgovarajuće naznačio svaku pomoć koju sam dobio pored pomoći mentora i akademskih tutora/ica.

Sarajevo, datum .....

Potpis:

_____

Amina Alagić

Sadržaj

Popis slika **v**

Popis tabela **vi**

1 Uvod **1**
1.1 Obrazloženje teme 1
1.2 Struktura rada 1

2 SVD faktorizacija **2**
2.1 Zašto je važna SVD faktorizacija? 2
2.2 Definicija 3
2.3 Singularne vrijednosti i veza sa sopstvenim vrijednostima 3
2.4 Varijante SVD 5
2.5 Geometrijska interpretacija 6

3 Tehnike izračunavanja SVD **9**
3.1 Ručno računanje 9
3.2 Primjeri SVD faktorizacije 11
3.3 Numeričko računanje 12
3.3.1 Metode zasnovane na bidijagonalizaciji 12

4 Primjena SVD faktorizacije na kompresiju slike **15**
4.1 Redukcija dimenzionalnosti 15
4.2 Predstavljanje slike u računaru 17
4.3 Kompresija slike 19
4.4 Opis algoritma za kompresiju slike 19
4.5 Analiza zauzeća memorije 19
4.6 Metrike 20
4.7 Primjer kompresije monohromatske slike 20
4.8 Primjer kompresije slike u boji 24
4.9 Zaključak 26

Prilozi **28**

Literatura **29**

Indeks pojmova **29**

Popis slika

2.1 SVD faktorizacija matrice kod koje je $m > n$ 4
2.2 Prva varijanta 6
2.3 Druga varijanta 6
2.4 Treća varijanta 6
2.5 Četvrta varijanta 6
2.6 Geometrijska interpretacija 7

4.1 Prikaz SVD faktorizacije u obliku sume 16
4.2 SVD faktorizacija matrice A 16
4.3 Aproksimacija matrice A matricama ranga 1, 2 i 3 17
4.4 Originalna slika 18
4.5 Monohromatska slika 18
4.6 RGB komponente slike 18
4.7 Matrični prikaz RGB komponenti 18
4.8 Originalna slika 20
4.9 Kompresija monohromatske slike korištenjem k singularnih vrijednosti 21
4.10 Singularne vrijednosti monohromatske slike 23
4.11 Kumulativna suma singularnih vrijednosti monohromatske slike 23
4.12 Srednja kvadratna greška za kompresovanu monohromatsku sliku 24
4.13 Kompresija slike u boji korištenjem k singularnih vrijednosti 25

Popis tabela

4.1 Zauzeće memorije za kompresovanu monohromatsku sliku 22
4.2 Zauzeće memorije za kompresovanu sliku u boji 26

Poglavlje 1

Uvod

1.1 Obrazloženje teme

U današnje vrijeme je potrebno pohranjivati i prenositi veliku količinu multimedijalnih podataka, a posebno slika. Te slike su često velikih dimenzija i korisno ih je kompresovati kako bi zauzimale manje memorijskog prostora i brže se prenosile. Kao dobra metoda za kompresiju pokazala se faktorizacija pomoću singularnih vrijednosti (SVD). U ovom radu se detaljno obrađuju SVD i primjena SVD na kompresiju slike, kao i neke tehnike za izračunavanje ove faktorizacije.

1.2 Struktura rada

Rad je podijeljen na tri poglavlja:

- Drugo poglavlje uvodi osnovne pojmove o faktorizaciji pomoću singularnih vrijednosti. Opisuje se i geometrijska interpretacija faktorizacije.

- Treće poglavlje obrađuje tehnike izračunavanja SVD. Detaljno se opisuje način ručnog računanja ove faktorizacije. Spominju se tehnike koje se koriste za implementaciju SVD na računaru, a ukratko se opisuju algoritmi zasnovani na bidijagonalizaciji.

- Četvrto poglavlje posvećeno je primjeni SVD na kompresiju slike. Prvo se obrađuje redukcija dimenzionalnosti pomoću SVD, a zatim se na konkretnim primjerima pokazuje kompresija slike.

Poglavlje 2

SVD faktorizacija

2.1 Zašto je važna SVD faktorizacija?

Jedan od najznačajnijih pristupa u numeričkoj linearnoj algebri je korištenje matričnih faktorizacija. Faktorizacija matrice je prikaz matrice kao proizvoda drugih matrica specijalne strukture (ortogonalna, trougaona, dijagonalna i slično). Različite faktorizacije pogodne su za implementaciju efikasnih algoritama na računaru.
Postoje dvije grupe matričnih faktorizacija: one povezane sa rješavanjem sistema linearnih jednačina i one povezane sa sopstvenim vrijednostima matrice [1]. **Faktorizacija pomoću singularnih vrijednosti** ili **SVD faktorizacija** (*engl. Singular Value Decomposition*), koja je tema ovog rada, spada u matrične faktorizacije povezane sa sopstvenim vrijednostima.

Pomoću SVD je moguće faktorizirati proizvoljnu matricu, što nije slučaj kod mnogih poznatih faktorizacija koje zahtijevaju da matrica bude specifičnog oblika, a algoritmi za SVD su numerički stabilni. Zbog toga je u novije vrijeme SVD faktorizacija postala važan alat za rješavanje različitih problema linearne algebre. Koristi se za nalaženje inverzne i pseudoinverzne matrice, za rješavanje linearnog problema najmanjih kvadrata, za određivanje ranga matrice, kao i za aproksimaciju matricom nižeg ranga. SVD faktorizacija je posebno interesantna zbog široke primjene u nauci i inženjerstvu. U računarskim naukama SVD se primijenjuje za kompresiju slike, u digitalnom procesiranju signala, te u oblastima mašinskog učenja kao što su PCA (*engl. Principal Component Analysis*) i sistemi za preporučivanje.

U mnogim oblastima nauke podaci su raspoređeni u velike matrice. Međutim, te matrice vrlo često imaju mali rang, što znači da velika količina podataka nije važna i može se zanemariti. SVD faktorizacija predstavlja numeričku metodu koja može izdvojiti važne informacije iz velikog skupa podataka. Time se postiže redukcija dimenzionalnosti. Naprimjer, slike se mogu predstaviti preko velikog broja piksela. Međutim, većina slika se može značajno kompresovati, što će biti i pokazano u ovom radu [2].

Za otkriće SVD faktorizacije zaslužno je 5 naučnika: **Beltrami**[1], **Jordan**[2], **Sylvester**[3], **Schmidt**[4] i **Weyl**[5]. Beltrami, Jordan i Sylvester su, neovisno jedan od drugog, došli do zaključaka

[1] Eugenio Beltrami (1835-1900), italijanski matematičar.
[2] Camille Jordan (1838-1922), francuski matematičar.
[3] James Joseph Sylvester (1814-1897), engleski matematičar.
[4] Erhard Schmidt (1876-1959), njemačko-estonski matematičar.
[5] Hermann Weyl (1885-1955), njemački matematičar.

o SVD-u krajem 19. stoljeća izučavajući linearnu algebru, a Schmidt i Weyl početkom 20. stoljeća izučavajući oblast integralnog računa. U drugoj polovini 20. stoljeća objavljeni su praktični algoritmi za izračunavanje SVD što je doprinijelo popularizaciji ove faktorizacije [3].

2.2 Definicija

SVD faktorizacija faktorizira matricu A dimenzija m x n u proizvod

$$A = U\Sigma V^T,$$

gdje je U ortogonalna matrica dimenzija m x m, Σ dijagonalna matrica dimenzija m x n, a V ortogonalna matrica dimenzija n x n [4]. Kolone matrice U nazivaju se **lijevi singularni vektori**, a kolone matrice V **desni singularni vektori**. Elementi na dijagonali matrice Σ nazivaju se **singularne vrijednosti** matrice A i za njih vrijedi

$$\sigma_1 \geq \sigma_2 \geq ... \geq \sigma_{min\{m,n\}} \geq 0.$$

Dakle, singularne vrijednosti su nenegativne i poredane su od najveće do najmanje, a označavaju se sa σ_i. U nastavku rada kolone matrice U označavat će se sa u_i, a kolone matrice V sa v_i.

Izraz za SVD može se napisati i u obliku $AV = U\Sigma$, odnosno posmatrajući kolone matrica U i V:

$$Av_i = \sigma_i u_i. \tag{2.1}$$

Vrijedi napomenuti da je SVD faktorizacija moguća i za kompleksne matrice, a tada ima oblik

$$A = U\Sigma V^*,$$

gdje su matrice U i V unitarne[6], a matrica Σ dijagonalna. U ovom radu će se podrazumijevati da su matrice realne.

2.3 Singularne vrijednosti i veza sa sopstvenim vrijednostima

SVD faktorizacija i singularne vrijednosti usko su vezane sa sopstvenim vrijednostima matrice, a u ovom poglavlju bit će prikazane neke osobine SVD faktorizacije koje proizilaze iz toga.

Kod simetrične matrice, sopstvene vrijednosti su realne, a sopstveni vektori ortogonalni. Svaka realna simetrična matrica M može se faktorizirati kao $M = Q\Lambda Q^T$, gdje je matrica Q ortogonalna matrica čije su kolone sopstveni vektori matrice M, a matrica Λ dijagonalna matrica na čijoj dijagonali su sopstvene vrijednosti matrice M. Ova faktorizacija naziva se spektralna faktorizacija. SVD faktorizacija, na izvjestan način, predstavlja generalizaciju ove rastave s obzirom da su matrice U i V ortogonalne, matrica Σ dijagonalna, a moguće je faktorizirati proizvoljnu matricu [5].

[6]Kompleksna matrica X je unitarna ukoliko vrijedi $X^*X = XX^* = I$ gdje je X^* konjugovano transponovana matrica matrice X. Unitarna matrica je analogna ortogonalnoj za realne matrice.

Sada ćemo vidjeti kako su ove dvije faktorizacije povezane. Bez gubitka općenitosti pretpostavimo da je matrica A formata m x n gdje je $m \geq n$ i da je $A = U\Sigma V^T$ njena SVD faktorizacija.
Za matrice A^TA i AA^T vrijedi (U i V su ortogonalne, pa je iskorišteno $U^TU = I$ i $V^TV = I$) [5]:

$$A^TA = (U\Sigma V^T)^T(U\Sigma V^T) = V\Sigma^T U^T U\Sigma V^T = V(\Sigma^T\Sigma)V^T, \tag{2.2}$$

$$AA^T = (U\Sigma V^T)(U\Sigma V^T)^T = U\Sigma V^T V\Sigma^T U^T = U(\Sigma\Sigma^T)U^T. \tag{2.3}$$

Kako je matrica A^TA simetrična, matrica V ortogonalna, a $\Sigma^T\Sigma$ dijagonalna sa elementima σ_i^2 na dijagonali, izraz 2.2 predstavlja spektralnu faktorizaciju matrice A^TA. Analogno, izraz 2.3 predstavlja spektralnu faktorizaciju matrice AA^T. Iz ovih izraza zaključujemo sljedeće:

- singularne vrijednosti matrice A su korijeni sopstvenih vrijednosti matrice A^TA, kao i matrice AA^T,
- kolone matrice V su sopstveni vektori matrice A^TA,
- kolone matrice U su sopstveni vektori matrice AA^T.

Ovdje je značajno obratiti pažnju na prvi navedeni zaključak - singularne vrijednosti matrice A su korijeni sopstvenih vrijednosti matrice A^TA, kao i matrice AA^T. Naime, matrice A^TA i AA^T su različitih dimenzija, odnosno različitih dimenzija su i matrice $\Sigma^T\Sigma$ i $\Sigma\Sigma^T$. To znači da matrica A^TA ima n sopstvenih vrijednosti, a matrica AA^T m sopstvenih vrijednosti. Međutim, prvih n sopstvenih vrijednosti matrice AA^T su jednake sopstvenim vrijednostima matrice A^TA, a ostale su 0.

Dakle, matrica A ima dva skupa singularnih vektora: desni (pridruženi sopstvenim vrijednostima A^TA) i lijevi (pridruženi sopstvenim vrijednostima AA^T), ali A ima samo jedan skup singularnih vrijednosti s obzirom da AA^T ima jednake pozitivne sopstvene vrijednosti kao i A^TA.

Rang matrice jednak je broju nenultih singularnih vrijednosti. Ako je $m > n$ matrica Σ će na glavnoj dijagonali imati n singularnih vrijednosti i $m - r$ redova nula, a ako je $m < n$ na glavnoj dijagonali će imati m singularnih vrijednosti i $n - r$ kolona nula. Na slici 2.1 su prikazane strukture matrica U, Σ i V^T za slučaj kada je $m > n$.

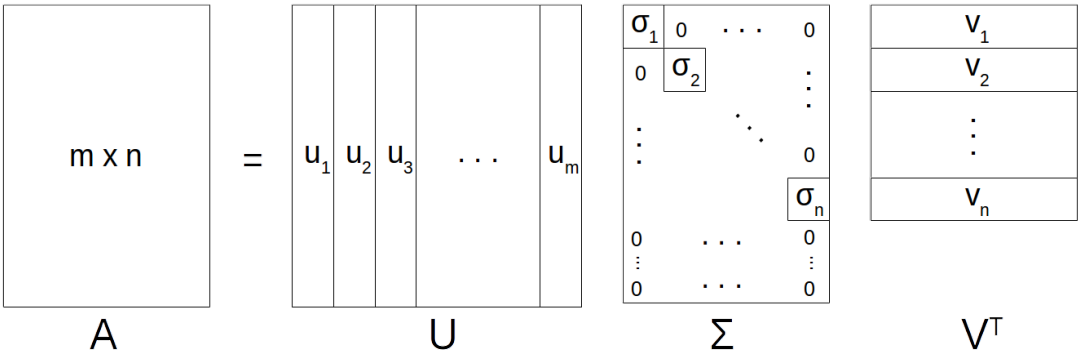

Slika 2.1: SVD faktorizacija matrice kod koje je $m > n$

2.4 Varijante SVD

Postoji nekoliko varijanti SVD faktorizacije koje se razlikuju po dimenzijama matrica U, Σ i V, a značajne su sa aspekta utroška memorije [6].

1. Prva varijanta (*engl. full SVD*) je standardna forma:

   $$A = U\Sigma V^T,$$

   gdje je U ortogonalna matrica dimenzija m x m, Σ dijagonalna matrica dimenzija m x n, a V ortogonalna matrica dimenzija n x n.

2. Druga varijanta je

   $$A = U_k\Sigma_k V_k^T,$$

   gdje je

   $$k = min\{m,n\}.$$

   Tada je matrica Σ_k kvadratna i sadrži prvih k singularnih vrijednosti, a matrice U_k i V_k sadrže prvih k kolona matrica U i V, respektivno. Kada je jedna dimenzija, m ili n, značajno manja od druge, zauzeće memorije je puno manje u odnosu na prvu varijantu.

3. Treća varijanta je

   $$A = U_r\Sigma_r V_r^T,$$

   gdje je r rang matrice A.
   Matrica Σ_r je kvadratna, a u memoriji se čuva samo prvih r kolona matrica U i V. Ukoliko matrica ima puni rang, tj. ako je $r = min\{m,n\}$, onda je ova varijanta ekvivalentna prethodnoj.

4. Četvrta varijanta je

   $$A = U_k\Sigma_k V_k^T,$$

   gdje je $k < r$.
   Čuva se prvih k kolona matrica U i V koje su pridružene prvih k singularnih vrijednosti.

Druga i treća varijanta, koje se još nazivaju i **reducirane varijante**, zasnivaju se na uklanjanju elemenata matrica U, V i Σ koji ne doprinose proizvodu $U\Sigma V^T$. Kod treće varijante, kada je $m > n$, matrica Σ sadrži $m-r$ redova sa svim nulama. Zbog toga $m-r$ kolona matrica U i $n-r$ redova matrice V^T ne doprinose proizvodu $U\Sigma V^T$. Dakle, moguće je ukloniti $m-r$ kolona matrica U, $m-r$ redova matrice Σ i $n-r$ redova matrice V^T, a da to ne promijeni proizvod $U\Sigma V^T$. Slično vrijedi i za drugu varijantu.
Ove dvije varijante su značajne jer vidimo da se u memoriji umjesto matrice A mogu čuvati reducirane varijante matrica U, Σ i V koje će kada se pomnože dati početnu matricu A čime se smanjuje utrošak memorije.

Kod četvrte varijante dolazi do gubitka informacija, odnosno proizvod $U_k\Sigma_k V_k^T$ ne daje početnu matricu A. Međutim, vidjet ćemo u nastavku da se ova varijanta može koristiti kako bi se matrica A aproksimirala matricom nižeg ranga.

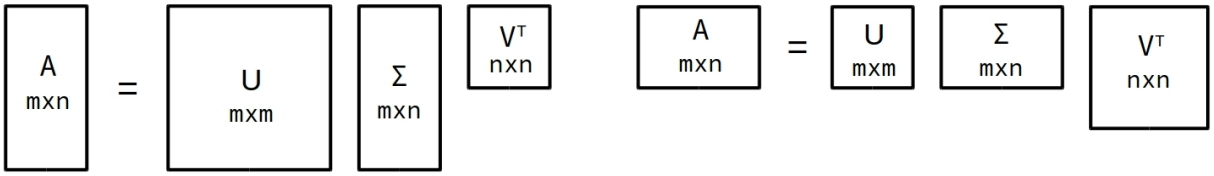

(a) $m > n$ (b) $m \leq n$

Slika 2.2: Prva varijanta

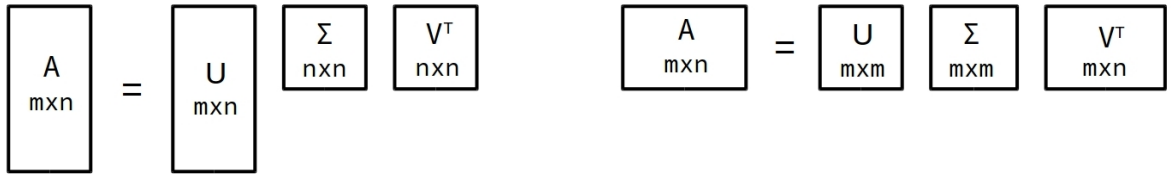

(a) $m > n$ (b) $m \leq n$

Slika 2.3: Druga varijanta

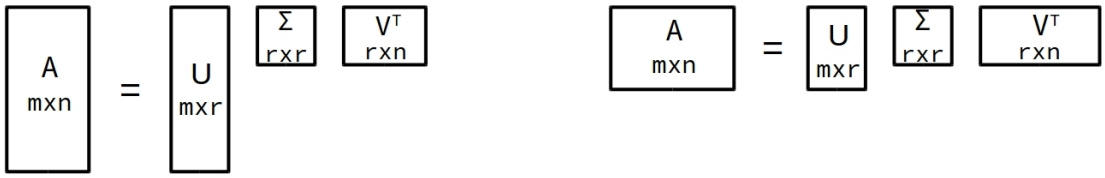

(a) $m > n$ (b) $m \leq n$

Slika 2.4: Treća varijanta

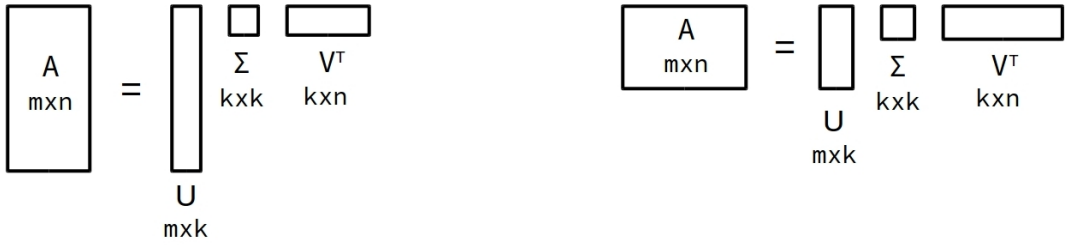

(a) $m > n$ (b) $m \leq n$

Slika 2.5: Četvrta varijanta

2.5 Geometrijska interpretacija

Pretpostavimo da je matrica A formata $2x2$.
Bilo koju matricu A možemo posmatrati kao transformaciju koja neki kružni disk u dvodimenzionalnom prostoru transformira u elipsu, odnosno vektor x koji predstavlja koordinate neke tačke unutar diska prevodi u Ax. SVD faktorizacija razlaže tu transformaciju u tri koraka [4]:

1. S obzirom da ortogonalna matrica u dvodimenzionalnom prostoru predstavlja rotaciju tačke oko koordinatnog početka, matrica V^T rotira disk u inicijalni položaj tako da se skaliranje u narednom koraku vrši po koordinatnim osama;

2. Matrica Σ, kao dijagonalna, rasteže disk u elipsu. Singularne vrijednosti predstavljaju koeficijente skaliranja po koordinatnim osama, odnosno dužine poluosa elipse ukoliko je disk imao poluprečnik dužine 1;

3. Matrica U, također ortogonalna, rotira elipsu u konačni položaj.

Na slici 2.6 je prikazana korak po korak transformacija jedinične kružnice matricom $A = \begin{bmatrix} -5/4 & 1/2 \\ 3/4 & 7/4 \end{bmatrix}$.

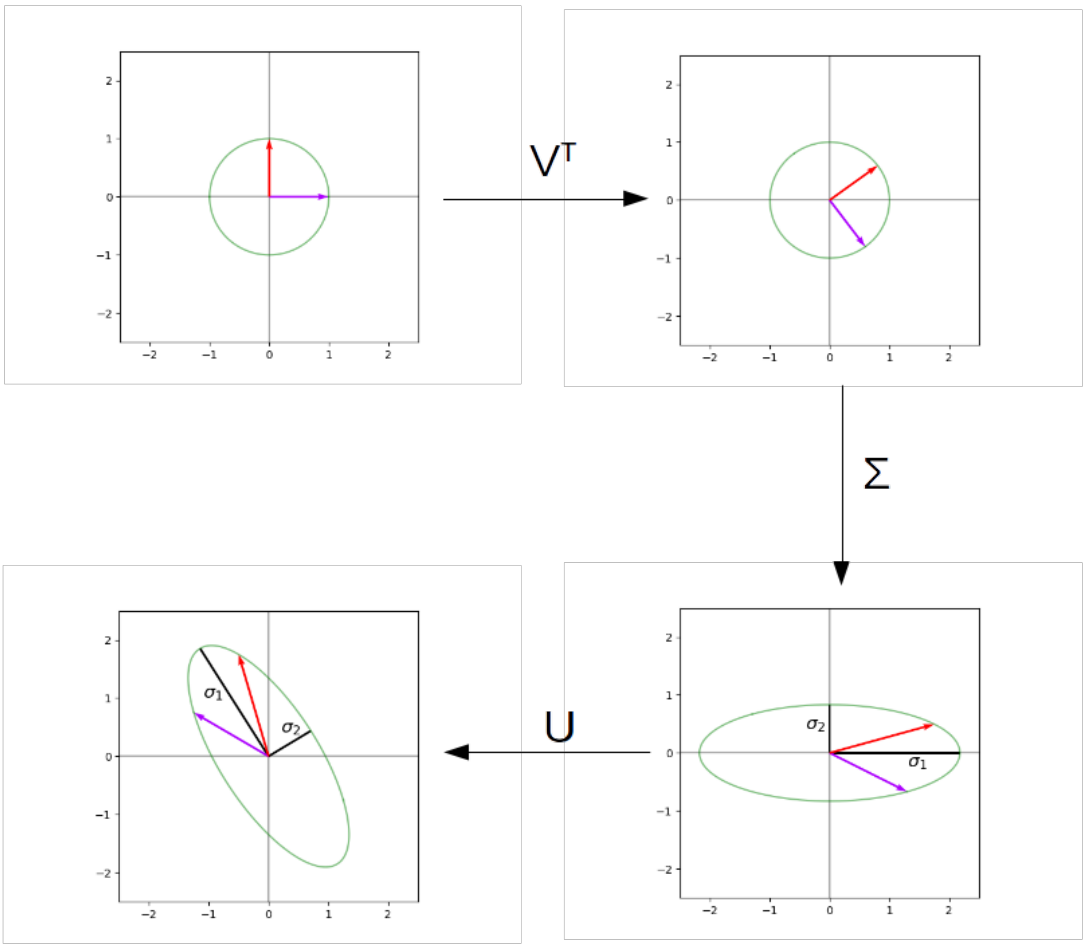

Slika 2.6: Geometrijska interpretacija

Ovakva interpretacija se može povezati i sa ranije spomenutom redukcijom dimenzionalnosti. Naime, SVD se može posmatrati i kao metoda koja vrši projekciju nekog višedimenzionalnog prostora na neki manjedimenzionalni prostor. Naprimjer, da je u prethodno navedenom primjeru singularna vrijednost σ_2 iznosila 0, tačke jedinične kružnice ne bi se projicirale u elipsu. Umjesto toga, sve tačke bi bile na istom pravcu. Time bi se izvršila projekcija iz dvodimenzionalnog u jednodimenzionalni prostor. Također, da je singularna vrijednost σ_2 bila jako mala, ali ne 0, ona bi se mogla posmatrati kao 0. Time bi se dvodimenzionalni prostor aproksimirao jednodimenzionalnim.

* * *

U ovom poglavlju uvedeni su osnovni pojmovi vezani za SVD faktorizaciju, data je njena definicija, kao i geometrijska interpretacija, a objašnjena je i veza SVD i sopstvenih vrijednosti matrice. U nastavku će biti spomenuti načini na koje se SVD može izračunati.

Poglavlje 3

Tehnike izračunavanja SVD

U ovom poglavlju bit će opisane neke tehnike izračunavanja SVD faktorizacije. Prvo će biti prikazana metoda koja se može koristiti za ručno računanje SVD-a matrica manjih dimenzija. S obzirom da je za praktične primjene jako bitno da algoritam bude efikasan, bit će spomenute aktuelne tehnike koje se koriste za implementaciju SVD faktorizacije na računaru.

U nastavku će se, ako nije naglašeno, podrazumijevati da je $m \geq n$. Kada je $m < n$ algoritmi se mogu primijeniti na matricu A^T, pri čemu će singularne vrijednosti ostati iste.

3.1 Ručno računanje

SVD faktorizacija matrice A može se izračunati koristeći činjenicu da su singularne vrijednosti matrice A jednake korijenima pozitivnih sopstvenih vrijednosti matrice A^TA (kao i AA^T). Kolone matrice V su sopstveni vektori matrice A^TA, tačnije v_i je normalizirani sopstveni vektor matrice A^TA pridružen sopstvenoj vrijednosti $\sigma_i{}^2$, a u_i se može dobiti iz izraza 2.1 kao

$$u_i = \frac{1}{\sigma_i} A v_i. \tag{3.1}$$

Alternativno, kada je $m > n$, moguće je prvo pronaći kolone matrice U koje su sopstveni vektori matrice AA^T, a zatim odrediti v_i iz relacije $v_i = \frac{1}{\sigma_i} A^T u_i$.

Primjer 3.1: Odrediti SVD faktorizaciju matrice $A = \begin{bmatrix} 6 & 2 \\ -1 & 3 \end{bmatrix}$.

Prvi korak je pronaći matricu A^TA:

$$A^TA = \begin{bmatrix} 6 & -1 \\ 2 & 3 \end{bmatrix} \cdot \begin{bmatrix} 6 & 2 \\ -1 & 3 \end{bmatrix} = \begin{bmatrix} 37 & 9 \\ 9 & 13 \end{bmatrix}.$$

Sada je potrebno odrediti sopstvene vrijednosti matrice A^TA, tj. riješiti jednačinu $det(A^TA - \lambda I) = 0$ po λ:

$$\begin{vmatrix} 37-\lambda & 9 \\ 9 & 13-\lambda \end{vmatrix} = 0$$

$$(37-\lambda)\cdot(13-\lambda) = 81.$$

Iz posljednje jednačine zaključujemo da su tražene sopstvene vrijednosti $\lambda_1 = 40$ i $\lambda_2 = 10$. Dakle, singularne vrijednosti matrice A su $\sigma_1 = 2\sqrt{10}$ i $\sigma_2 = \sqrt{10}$. Ove vrijednosti nalaze se

na dijagonali matrice Σ, u opadajućem redoslijedu:

$$\Sigma = \begin{bmatrix} 2\sqrt{10} & 0 \\ 0 & \sqrt{10} \end{bmatrix}.$$

Sopstveni vektori pridruženi odgovarajućim sopstvenim vrijednostima dobijaju se iz relacije:

$$(A^T A - \lambda I)v_i = 0. \tag{3.2}$$

Uvrštavanjem $\lambda_1 = 40$ u relaciju 3.2 dolazi se do matrične jednačine:

$$\begin{bmatrix} -3 & 9 \\ 9 & -27 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

odnosno do sistema jednačina:

$$-3x_1 + 9x_2 = 0$$
$$9x_1 - 27x_2 = 0.$$

Rješenje ovog sistema je $(x_1, x_2) = (3x_1, x_1)$.
Pazeći da sopstveni vektor ne smije biti nula vektor, biramo proizvoljnu vrijednost x_1, pa je sopstveni vektor pridružen $\lambda_1 = 40$:

$$v_1 = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

Na sličan način dobija se i sopstveni vektor pridružen $\lambda_2 = 10$:

$$v_2 = \begin{bmatrix} -\frac{1}{3} \\ 1 \end{bmatrix}.$$

Normalizirane verzije sopstvenih vektora su: $v_1 = \begin{bmatrix} \frac{3}{\sqrt{10}} \\ \frac{1}{\sqrt{10}} \end{bmatrix}$ i $v_2 = \begin{bmatrix} -\frac{1}{\sqrt{10}} \\ \frac{3}{\sqrt{10}} \end{bmatrix}$.

Kolone matrice V su vektori v_1 i v_2:

$$V = \begin{bmatrix} \frac{3}{\sqrt{10}} & -\frac{1}{\sqrt{10}} \\ \frac{1}{\sqrt{10}} & \frac{3}{\sqrt{10}} \end{bmatrix}.$$

Vektore u_i nalazimo iz relacije 3.1:

$$u_1 = \frac{1}{\sigma_1} A v_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$u_2 = \frac{1}{\sigma_2} A v_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

Kolone matrice U su vektori u_1 i u_2:

$$V = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

Konačno, odredili smo sve što je potrebno za SVD faktorizaciju matrice A:

$$A = U \Sigma V^T,$$

$$A = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} 2\sqrt{10} & 0 \\ 0 & \sqrt{10} \end{bmatrix} \cdot \begin{bmatrix} \frac{3}{\sqrt{10}} & \frac{1}{\sqrt{10}} \\ -\frac{1}{\sqrt{10}} & \frac{3}{\sqrt{10}} \end{bmatrix}.$$

3.2 Primjeri SVD faktorizacije

Sada će biti prikazani još neki primjeri SVD faktorizacije matrica koje nisu kvadratne, kao i matrice koja nema puni rang.

Primjer 3.2: SVD faktorizacija matrice $B = \begin{bmatrix} 2 & 0 & 1 \\ 0 & 2 & 2 \end{bmatrix}$ je:

$$B = \begin{bmatrix} \frac{1}{\sqrt{5}} & \frac{-2}{\sqrt{5}} \\ \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} \end{bmatrix} \cdot \begin{bmatrix} 3 & 0 & 0 \\ 0 & 2 & 0 \end{bmatrix} \cdot \begin{bmatrix} \frac{2}{3\sqrt{5}} & \frac{4}{3\sqrt{5}} & \frac{\sqrt{5}}{3} \\ \frac{-2}{\sqrt{5}} & \frac{1}{\sqrt{5}} & 0 \\ -\frac{1}{3} & -\frac{2}{3} & \frac{2}{3} \end{bmatrix}.$$

Kod matrice B je $m < n$. Nakon što su određene singularne vrijednosti i postavljene na dijagonalu matrice Σ, bilo je potrebno dodati jednu kolonu sa svim nulama na matricu Σ kako bi njene dimenzije bile odgovarajuće.

Primjer 3.3: SVD faktorizacija matrice $C = \begin{bmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 3 \\ 3 & 1 \end{bmatrix}$ je:

$$C = \begin{bmatrix} \frac{5}{5\sqrt{2}} & \frac{1}{\sqrt{10}} & \frac{1}{\sqrt{35}} & -\frac{11}{5\sqrt{7}} \\ \frac{3}{5\sqrt{2}} & -\frac{1}{\sqrt{10}} & -\sqrt{\frac{5}{7}} & -\frac{1}{5\sqrt{7}} \\ \frac{2\sqrt{2}}{5} & \sqrt{\frac{2}{5}} & 0 & \frac{\sqrt{7}}{5} \\ \frac{2\sqrt{2}}{5} & -\sqrt{\frac{2}{5}} & \frac{3}{\sqrt{35}} & \frac{2}{5\sqrt{7}} \end{bmatrix} \cdot \begin{bmatrix} 5 & 0 \\ 0 & \sqrt{5} \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \cdot \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}.$$

Kod matrice C je $m > n$, pa je pogodno, umjesto matrice C^TC izračunati matricu CC^T i na osnovu nje odrediti vektore u_i (kao sopstvene vektore matrice CC^T) i singularne vrijednosti, a zatim na osnovu u_i odrediti v_i. Ovdje je na dijagonalnu matricu sa singularnim vrijednostima bilo potrebno dodati 2 reda sa svim nulama kako bi matrica imala odgovarajuće dimenzije.

Primjer 3.4: SVD faktorizacija matrice $D = \begin{bmatrix} 1 & 1 & 2 \\ 3 & 7 & 5 \\ 2 & 2 & 4 \\ 3 & 3 & 6 \end{bmatrix}$ je:

$$D = \begin{bmatrix} 0.1896 & 0.18835 \\ 0.7047 & -0.7095 \\ 0.3792 & 0.3767 \\ 0.5688 & 0.5651 \end{bmatrix} \cdot \begin{bmatrix} 12.5831 & 0 \\ 0 & 2.9437 \end{bmatrix} \cdot \begin{bmatrix} 0.3790 & 0.6030 & 0.7020 \\ 0.1727 & -0.7913 & 0.5865 \end{bmatrix}.$$

Ovo je reducirana varijanta SVD faktorizacije matrice D, tačnije treća varijanta iz poglavlja o varijantama SVD. Matrica D ima samo dvije singularne vrijednosti, odnosno njen rang je 2. S obzirom da je $min\{m,n\} = 3$, ova matrica nema puni rang. Zbog toga je pogodno koristiti reduciranu varijantu. Matrica U je formata 4 x 2 umjesto 4 x 4, matrica Σ formata 2 x 2 umjesto 4 x 3, a V^T formata 2 x 3 umjesto 3 x 3. To znači da je, pod pretpostavkom da se koristi prethodno objašnjeni način računanja SVD, dovoljno odrediti samo 2 vektora v_i i dva vektora u_i. Ovo dovodi i do manjeg utroška memorije, a proizvod $U\Sigma V^T$ ostaje isti.

3.3 Numeričko računanje

Vidjeli smo da je moguće odrediti SVD računanjem matrice A^TA (ili AA^T) i njenih sopstvenih vrijednosti. Zbog potrebe za rješavanjem sistema jednačina prilikom određivanja sopstvenih vrijednosti i zbog mogućeg gubitka informacija prilikom određivanja A^TA, ovaj način nije numerički stabilan, pa se u praksi koriste neke druge metode koje ne zahtijevaju eksplicitno računanje matrice A^TA. Postoje metode zasnovane na bidijagonalizaciji i iterativne **Jacobijeve**[1] metode [7].

U današnje vrijeme standard za izračunavanje SVD faktorizacije su algoritmi zasnovani na bidijagonalizaciji. Kod ovih algoritama prvo se matrica svodi na bidijagonalnu formu, a zatim se određuje SVD bidijagonalne matrice. Historijski prvi iz ove grupe je **Golub**[2]**-Kahan**[3] **algoritam**, objavljen 1965. godine. Značajne modifikacije ovog algoritma koje se danas najviše koriste su: **Golub-Reinsch**[4] **algoritam**, iz 1970. i **Demmel**[5]**-Kahan algoritam** iz 1990. Sva 3 koriste **Householderove**[6] transformacije za svođenje na bidijagonalnu matricu i različite varijante QR faktorizacije prilagođene za određivanje SVD.

Druga grupa algoritama su Jacobijeve metode koje su zasnovane na transformacijama pomoću Jacobijevih rotacija [7]. Ove metode predstavljaju generalizaciju Jacobijeve metode za nalaženje sopstvenih vrijednosti simetrične matrice (spektralnu dekompoziciju) iz 1846. godine. Najznačajniji algoritmi iz ove grupe su: **jednostrana Jacobijeva metoda** i **dvostrana Jacobijeva metoda** ili **Kogbetliantzov**[7] **algoritam** iz 1955. godine.

3.3.1 Metode zasnovane na bidijagonalizaciji

Algoritmi iz ove grupe sastoje se iz dva koraka [7] [8]:

1. Svesti matricu A na bidijagonalnu formu:

   $$A = UBV^T.$$

   Matrice U i V su ortogonalne, a B je oblika $\begin{bmatrix}\hat{B}\\0\end{bmatrix}$ gdje je $\hat{B}$ gornja bidijagonalna matrica. U je formata m x m, V formata n x n, a B formata m x n.
   Gornja bidijagonalna matrica ima nenulte elemente na glavnoj i sporednoj dijagonali iznad glavne, a ostali elementi su nule:

   $$\hat{B} = \begin{bmatrix} b_1 & d_1 & & & \\ & b_2 & d_2 & & \\ & & \ddots & \ddots & \\ & & & b_{n-1} & d_{n-1} \\ & & & & b_n \end{bmatrix}.$$

   Proces svođenja na bidijagonalnu formu naziva se **bidijagonalizacija**.

[1] Carl Gustav Jacob Jacobi (1804-1851), njemački matematičar.
[2] Gene Howard Golub (1932-2007), američki matematičar i informatičar.
[3] William Morton Kahan (1933-), kanadski matematičar i informatičar.
[4] Christian Reinsch (1934-), njemački matematičar.
[5] James Demmel (1955-), američki matematičar i informatičar.
[6] Alston Scott Householder (1904-1993), američki matematičar.
[7] Ervand George Kogbetliantz (1888-1974), armensko-američki matematičar.

2. Izračunati SVD faktorizaciju bidijagonalne matrice.
   Nakon bidijagonalizacije, određuje se SVD bidijagonalne matrice:

$$\hat{B} = \hat{U}\hat{\Sigma}\hat{V}^T.$$

   Ako je SVD matrice B:

$$B = U_B \Sigma V_B^T,$$

   onda je SVD matrice A:

$$A = (UU_B)\Sigma(VV_B)^T.$$

   Matrice U_B, Σ i V_B mogu se dobiti iz relacija sa $\hat{U}$, $\hat{\Sigma}$ i $\hat{V}$:

$$U_B = \begin{bmatrix} \hat{U} & 0 \\ 0 & I_{m-n} \end{bmatrix},$$

$$\Sigma = \begin{bmatrix} \hat{\Sigma} \\ 0 \end{bmatrix},$$

$$V_B = \hat{V}.$$

   Konačni izraz za SVD faktorizaciju matrice A je:

$$A = \left(U \begin{bmatrix} \hat{U} & 0 \\ 0 & I_{m-n} \end{bmatrix} \right) \begin{bmatrix} \hat{\Sigma} \\ 0 \end{bmatrix} (V\hat{V})^T.$$

Dakle, potrebno je prvo izvršiti bidijagonalizaciju, a zatim odrediti SVD bidijagonalne matrice nekom metodom koja je zasnovana na QR faktorizaciji i koja može brzo odrediti SVD takve matrice. Tada će biti izračunato sve što je potrebno za SVD početne matrice.

U nekim primjenama nije potrebno računati sve tri matrice U, Σ i V, pa od toga zavisi i vrijeme potrebno za izračunavanje SVD. Pod pretpostavkom da su potrebne samo singularne vrijednosti, za prvi korak, tj. bidijagonalizaciju pomoću Householderovih transformacija potrebno je $4mn^2 - \frac{4}{3}n^3$ operacija. Drugi korak, tj. QR faktorizacija, može se izvršiti u vremenu reda n^2, pa se cijeli algoritam, kada je $m \geq n$ može izvršiti u vremenu reda mn^2 [9].

U nastavku će biti opisan jedan algoritam za bidijagonalizaciju. Zbog kompleksnosti, drugi korak algoritma ovdje neće biti prikazan.

Bidijagonalizacija

Postoje različiti algoritmi za bidijagonalizaciju, a ovdje će ukratko biti opisan Householderov algoritam.
Matrica B iz bidijagonalne forme može se odrediti nizom uzastopnih transformacija:

$$B = U_n ... U_1 A V_1 ... V_{n-2},$$

gdje su U_k i V_k Householderove matrice. U k-tom koraku može se izabrati U_k tako da se anulira posljednjih $m-k$ elemenata k-te kolone matrice B, a matrica V_k tako da se anulira posljednjih $n-k-1$ elemenata k-tog reda matrice B. Na kraju postupka se za U i V iz bidijagonalne forme dobija da je $U = U_n ... U_1$ i $V = V_1 ... V_{n-2}$ [7].

Postoje i druge metode za bidijagonalizaciju koje su u nekim slučajevima brže. Naprimjer, Lawson-Hanson-Chan bidijagonalizacija zahtijeva $2mn^2 + 2n^3$ operacija što je efikasnije u odnosu na Householderove transformacije u slučaju kada je $m > \frac{5}{3}n$ [7].

* * *

U ovom poglavlju detaljno je opisan pristup koji se koristi kod ručnog računanja SVD faktorizacije, a spomenuti su i algoritmi koji se koriste u praksi. U nastavku će biti prikazano kako se SVD može koristiti za kompresiju slike.

Poglavlje 4

Primjena SVD faktorizacije na kompresiju slike

S razvojem tehnologije, raste količina podataka koje je potrebno čuvati u memoriji, obrađivati, ali i slati. Zbog toga su tehnike kompresije podataka postale jako značajne. Ovdje će biti obrađena kompresija slike pomoću SVD faktorizacije.

4.1 Redukcija dimenzionalnosti

Prvo ćemo na jednostavnom primjeru pokazati koja je svrha redukcije dimenzionalnosti i kako se može postići ušteda memorije. Pogledajmo matricu A:

$$A = \begin{bmatrix} 1 & 2 & 3 & 4 \\ 2 & 4 & 6 & 8 \\ 5 & 10 & 15 & 20 \\ -3 & -6 & -9 & -12 \end{bmatrix}.$$

Može se primijetiti da su redovi ove matrice međusobno linearno zavisni, pa se matrica može predstaviti kao proizvod dva vektora:

$$A = \begin{bmatrix} 1 & 2 & 3 & 4 \\ 2 & 4 & 6 & 8 \\ 5 & 10 & 15 & 20 \\ -3 & -6 & -9 & -12 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 5 \\ -3 \end{bmatrix} \cdot \begin{bmatrix} 1 & 2 & 3 & 4 \end{bmatrix}.$$

Odavde se može zaključiti da je, umjesto da se čuva svih 16 elemenata matrice A, bolje čuvati dva vektora, odnosno 8 vrijednosti. Ovdje ta razlika nije velika, međutim kod matrica velikih dimenzija koje se susreću u praksi, ušteda memorijskog prostora može biti značajna. Upravo ovo je ideja redukcije dimenzionalnosti - ne čuvati u memoriji originalnu matricu, nego manju količinu podataka na osnovu kojih se može dobiti originalna matrica.

Redukcija dimenzionalnosti se može postići SVD faktorizacijom. Već smo vidjeli u poglavlju o varijantama SVD da se matrica A može zapisati koristeći samo r singularnih vrijednosti, odnosno r kolona matrica U i V, gdje je r rang matrice. Izraz za ovakvu, reduciranu, SVD faktorizaciju može se zapisati na sljedeći način:

$$A = \sum_{i=1}^{r} \sigma_i u_i {v_i}^T,$$

odnosno

$$A = \sigma_1 u_1 {v_1}^T + \sigma_2 u_2 {v_2}^T + \ldots + \sigma_r u_r {v_r}^T.$$

Ova suma je suma matrica ranga 1 i daje početnu matricu A. Ovo je prikazano na slici 4.1.

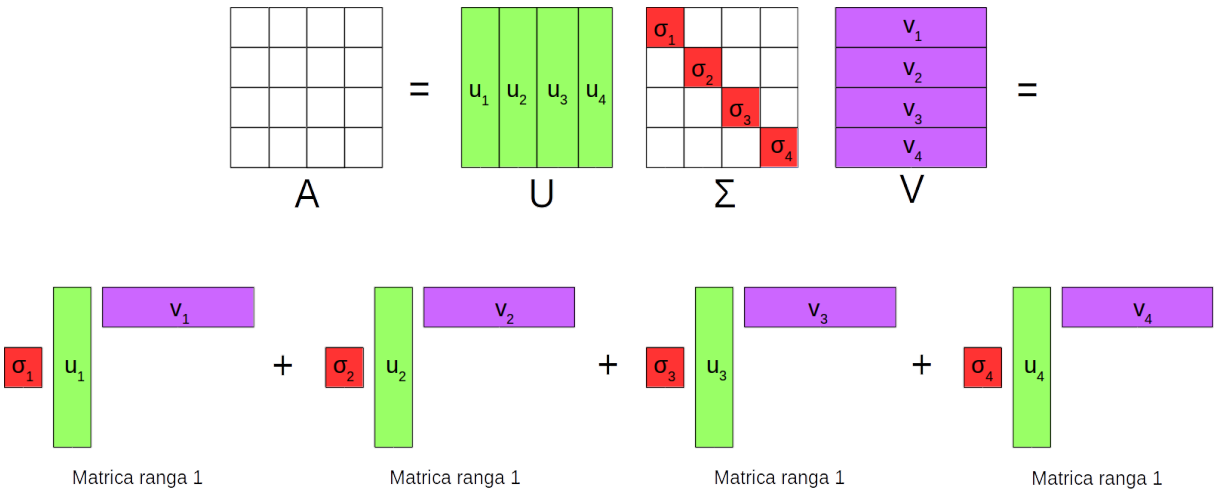

Slika 4.1: Prikaz SVD faktorizacije u obliku sume

Kada matrica nema puni rang, sumiranjem samo r komponenti doći će do uštede memorije. Ukoliko uzmemo prvih k ($k \leq r$) elemenata dobit ćemo matricu ranga k. Ovim se postiže **aproksimacija matrice** A **matricom nižeg ranga**, odnosno **redukcija dimenzionalnosti**. Suma $A_k = \sigma_1 u_1 {v_1}^T + \sigma_2 u_2 {v_2}^T + \ldots + \sigma_k u_k {v_k}^T$ predstavlja najbolju aproksimaciju matrice A matricom ranga k. To znači da ne postoji nijedna druga matrica ranga k koja je približnija matrici A od matrice A_k. Ova činjenica poznata je i kao **Eckart[1]-Youngova[2] teorema**, a jedna je od najkorištenijih i najznačajnijih osobina SVD faktorizacije [5].

Sada će na primjeru biti pokazana aproksimacija matrice matricom nižeg ranga [10]. Neka je potrebno izvršiti aproksimaciju matrice A:

$$A = \begin{bmatrix} 2 & 5 & 3 & 1 \\ 4 & 3 & 7 & 2 \\ 3 & 6 & 4 & 2 \\ 3 & 9 & 1 & 5 \end{bmatrix}.$$

SVD fakorizacija ove matrice je data na slici 4.2.

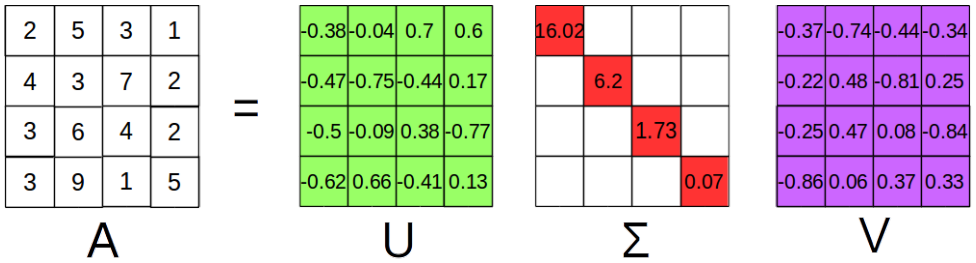

Slika 4.2: SVD faktorizacija matrice A

[1]Carl Henry Eckart (1902-1973), američki fizičar.
[2]Gale Young (1912-1990), američki fizičar i inženjer.

Poznato je da će proizvod $U\Sigma V^T$ dati matricu A, kao i suma $A = \sum_{i=1}^{4} \sigma_i u_i v_i{}^T$. Međutim, ako se ne sumiraju sva 4 elementa $\sigma_i u_i v_i{}^T$, nego samo prvih k, dobija se aproksimacija matrice A matricom ranga k.

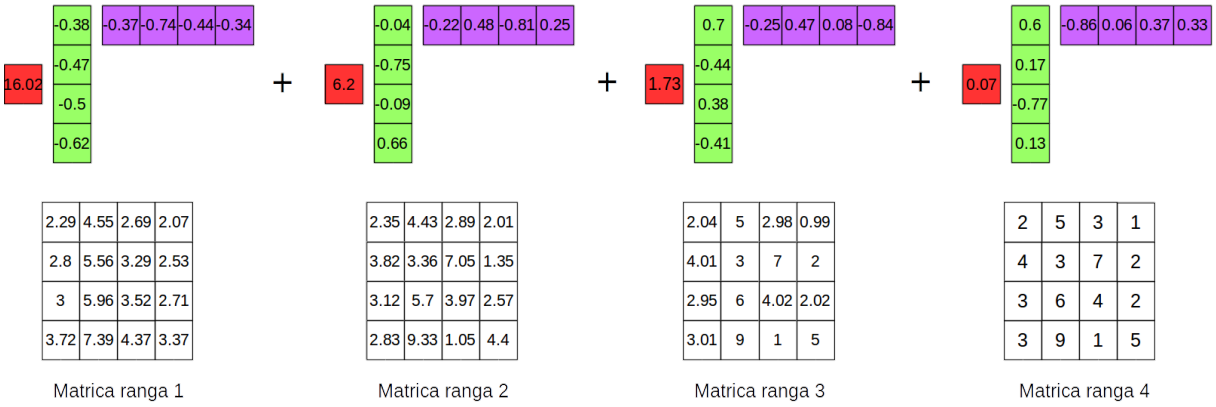

Slika 4.3: Aproksimacija matrice A matricama ranga 1, 2 i 3

Elementi matrica ranga 1 i ranga 2 se ne razlikuju previše u odnosu na elemente originalne matrice, međutim ne može se reći da predstavljaju dobru aproksimaciju. Elementi matrice ranga 3 se jako malo razlikuju od elemenata matrice ranga 4, tj. originalne matrice. Razlog tome je to što 4. singularna vrijednost iznosi samo 0.07. Ta singularna vrijednost je mala, pa dodavanje elementa $\sigma_4 u_4 v_4{}^T$ neće značajno uticati na već formiranu matricu ranga 3. Konkretno u ovom slučaju, pohranjivanje prva 3 vektora u_i, prva 3 vektora v_i i prve 3 singularne vrijednosti umjesto čitave matrice A ne bi dovelo do uštede memorije. Međutim, može se zamisliti matrica koja ima jako puno malih singularnih vrijednosti koje se mogu odbaciti.

4.2 Predstavljanje slike u računaru

Digitalna slika se može predstaviti kao mreža **piksela** (*engl. pixel*). U računarskoj memoriji se ta mreža predstavlja kao matrica. Elementi te matrice određuju intenzitet svakog piksela. Matrica je formata m x n, m predstavlja broj piksela po visini, a n broj piksela po širini slike. Postoje 3 načina predstavljanja slike u računaru:

- Crno-bijela slika - pikseli mogu imati vrijednosti 0 ili 1. Vrijednost 0 predstavlja crnu boju, a 1 bijelu.
- Monohromatska slika - u većini formata pikseli imaju vrijednost između 0 i 255. Vrijednost 0 predstavlja crnu boju, vrijednost 255 bijelu, a ostale vrijednosti predstavljaju različite nijanse sive boje.
- Slika u boji - predstavlja se sa 3 matrice koje specificiraju crvenu, zelenu i plavu komponentu slike. Dakle, kod slika u boji, za svaki piksel vežu se 3 vrijednosti između 0 i 255 koje predstavljaju intenzitet određene boje. Ovaj način predstavljanja slike naziva se **RGB model**.

U nastavku je matrični prikaz dijela slike nizozemskog slikara Mondriana. Rezolucija izdvojenog dijela smanjena je na 8 x 5.

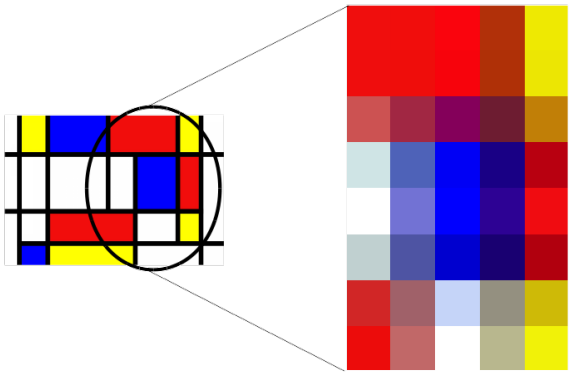

Slika 4.4: Originalna slika

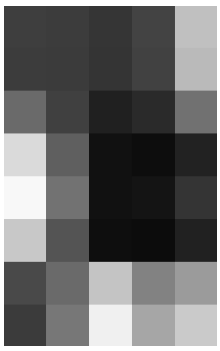

(a) Slika

62	61	57	73	217
61	61	56	72	215
108	67	35	47	132
224	100	18	15	40
255	121	18	22	61
205	88	15	13	39
74	111	211	144	177
60	123	255	180	225

(b) Matrica

Slika 4.5: Monohromatska slika

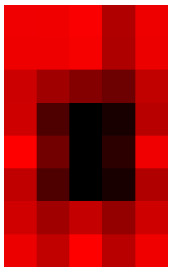

(a) Crvena

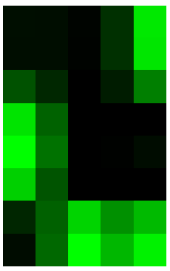

(b) Zelena

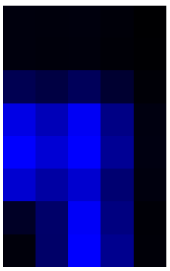

(c) Plava

Slika 4.6: RGB komponente slike

240	241	250	177	238
239	239	247	175	236
204	161	132	109	193
207	78	0	25	184
255	114	0	45	240
192	78	0	25	177
209	160	197	148	206
236	193	255	184	241

(a) Crvena

14	13	4	48	233
13	13	3	48	230
82	39	0	28	127
228	98	0	0	0
255	114	0	2	12
208	84	0	0	0
38	97	212	144	186
12	104	255	183	242

(b) Zelena

13	12	13	9	2
13	11	12	7	3
82	67	90	49	7
229	184	245	133	16
255	212	255	148	17
208	163	207	113	14
38	105	248	128	7
11	104	255	142	8

(c) Plava

Slika 4.7: Matrični prikaz RGB komponenti

4.3 Kompresija slike

Kompresija slike je proces smanjivanja količine podataka koji su potrebni za predstavljanje slike u računaru. Cilj kompresije je predstaviti sliku sa što manje bita čime se ostvaruje ušteda memorijskog prostora, ali i brži prenos slike. Postoje dvije vrste kompresije: **kompresija bez gubitaka** (*engl. lossless compression*) i **kompresija sa gubicima** (*engl. lossy compression*). Kod kompresije bez gubitaka, iz kompresovanih podataka je moguće u potpunosti rekonstruisati originalne, a kod kompresije sa gubicima dolazi do gubitka određene količine informacija [11]. Većina današnjih metoda za kompresiju slike, kao što je JPG, koriste kompresiju sa gubicima.

SVD faktorizacijom se može izvršiti kompresija slike sa gubicima. Upotrebljivost ove kompresije zasnovana je na nesavršenosti ljudskog oka.

4.4 Opis algoritma za kompresiju slike

Sada je jasno kako se pomoću SVD može kompresovati slika - potrebno je predstaviti sliku kao matricu, izračunati SVD te matrice i odrediti aproksimaciju matricom nižeg ranga što će omogućiti manje zauzeće memorije [12]. Za sliku u boji potrebne su tri matrice. Dakle, algoritam za kompresiju slike u boji se sastoji iz sljedećih koraka:

1. Učitati sliku;
2. Sačuvati sliku kao 3 matrice, po jedna za crvenu, zelenu i plavu komponentu;
3. Izračunati SVD faktorizaciju sve 3 matrice;
4. Formirati nove 3 matrice koristeći k singularnih vrijednosti;
5. Kombinovati crvenu, zelenu i plavu komponentu i prikazati rekonstruisanu sliku.

Koraci su isti i za monohromatsku sliku, osim što bi se umjesto tri matrice koristila jedna.

Za potrebe ovog rada, algoritam je implementiran u programskom jeziku Python. Za izračunavanje SVD faktorizacije korištena je funkcija *svd* iz biblioteke NumPy. Dokumentacija za ovu funkciju može se naći na linku [13]. NumPy za implementaciju SVD koristi funkciju _gesdd iz biblioteke za linearnu algebru LAPACK. Implementacija te funkcije zasnovana je na "podijeli pa vladaj" algoritmu za SVD. I za ostale operacije sa matricama korištena je biblioteka NumPy, a za rad sa slikom biblioteka PIL.

4.5 Analiza zauzeća memorije

Neka je slika rezolucije m x n predstavljena matricom A. Ta slika ima $m \cdot n$ piksela, pa će za čuvanje slike u memoriji biti potrebno $m \cdot n$ memorijskih lokacija za monohromatsku sliku, odnosno $3 \cdot m \cdot n$ za sliku u boji.
Za slučaj monohromatske slike, nakon određivanja SVD faktorizacije i uzimanja prvih k singularnih vrijednosti i singularnih vektora kako bi se izvršila aproksimacija, dobit će se matrice U_k formata m x k, Σ_k formata k x k i ${V_k}^T$ formata k x n. Treba napomenuti da matrica Σ_k ima elemente samo na glavnoj dijagonali, pa je dovoljno čuvati samo k elemenata sa dijagonale umjesto čitave matrice. Ukupno zauzeće memorije za ove 3 matrice je:

$$m \cdot k + k + k \cdot n,$$

odnosno

$$k(m+n+1).$$

Da bi se ostvarila kompresija slike tj. ušteda memorije potrebno je da bude:

$$k(m+n+1) < m \cdot n.$$

Ovo je moguće kada je k za koji se može napraviti dobra aproksimacija relativno mali broj, a m i n relativno veliki, što i jeste slučaj u praktičnim primjenama [14].
Ovaj zaključak vrijedi i za slike u boji.

4.6 Metrike

Za utvrđivanje kvaliteta kompresije slike, u narednom poglavlju ćemo koristiti dvije metrike:

- Odnos između količine podataka koja se čuva za kompresovanu i nekompresovanu sliku:

  $$\frac{k(m+n+1)}{m \cdot n} \cdot 100\%.$$

  Računat ćemo procenat zauzeća memorije kompresovane u odnosu na nekompresovanu sliku.

- Srednja kvadratna greška:

  $$\frac{1}{m \cdot n} \sum_{i=1}^{m} \sum_{j=1}^{n} (A(i,j) - A_k(i,j))^2.$$

  Sa A je označena matrica originalne slike, a sa A_k matrica slike rekonstruisane korištenjem k singularnih vrijednosti.

4.7 Primjer kompresije monohromatske slike

Zbog jednostavnosti prikaza ovisnosti između broja korištenih singularnih vrijednosti i kvaliteta kompresije, prvo će biti pokazana kompresija monohromatske slike. Bit će kompresovana slika 4.8 sa ekstenzijom .bmp. BMP format je format za pohranu digitalnih slika. Ovdje je izabran jer čuva sliku u nekompresovanom obliku, pa će biti lakše pokazati efekte kompresije pomoću SVD.

Slika 4.8: Originalna slika

Ova slika ima rezoluciju 3072 x 4608, pa je ukupan broj piksela 14 155 776. To znači da slika u memoriji zauzima 14.2MB. Za većinu primjena ovo je veliko zauzeće memorije i sliku je potrebno kompresovati.

Korištenjem opisanog algoritma slika je kompresovana uzimajući u obzir različit broj singularnih vrijednosti. U nastavku su rekonstruisane slike nastale korištenjem 1, 5, 10, 30, 100, 200, 1000 i 3072 (originalna slika) singularnih vrijednosti.

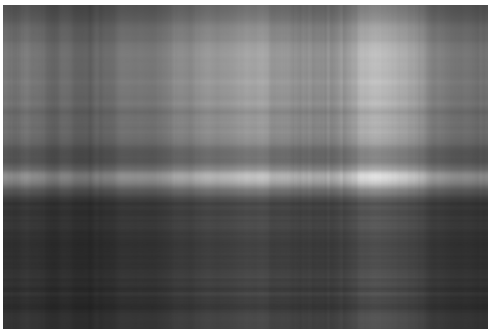

(a) $k = 1$

(b) $k = 5$

(c) $k = 10$

(d) $k = 30$

(e) $k = 100$

(f) $k = 200$

(g) $k = 1000$

(h) Originalna slika

Slika 4.9: Kompresija monohromatske slike korištenjem k singularnih vrijednosti

U tabeli 4.1 vidimo koliko je zauzeće memorije u odnosu na broj korištenih singularnih vrijednosti. Prikazano je zauzeće u bajtima (B), zauzeće u megabajtima (MB), kao i odnos između količine podataka koja se čuva za kompresovanu i nekompresovanu sliku.

Tabela 4.1: Zauzeće memorije za kompresovanu monohromatsku sliku

k	Zauzeće u B	Zauzeće u MB	Zauzeće u procentima
1	7 681	0.008	0.05%
5	38 405	0.04	0.27%
10	76 810	0.08	0.54%
30	230 430	0.23	1.63%
100	768 100	0.77	5.43%
200	1 536 200	1.54	10.85%
1000	7 681 000	7.68	54.26%

Kompresovane slike za $k = 1$ i $k = 5$ očekivano daju lošu aproksimaciju originalne slike. Za $k = 10$ se već može naslutiti koji su objekti na slici, a za $k = 30$ imamo poprilično dobru aproksimaciju s obzirom da ta slika zauzima samo 0.23MB. Za $k = 100$ je još uvijek uočljiva razlika u kvaliteti, međutim za $k = 200$ i više jako je teško primijetiti razliku u odnosu na originalnu sliku. Konkretno za $k = 200$, kompresovana slika zauzima samo 1.54MB ili 10.85% od originalne slike što predstavlja veliku uštedu memorije uz jako kvalitetnu aproksimaciju.

Sada možemo vidjeti i razlog zašto je SVD faktorizacija korisna za kompresiju slike. Bez obzira što slika ima ukupno 3072 singularne vrijednosti (ima puni rang), najveća količina informacija o slici sadržana je u prvih nekoliko. Velik broj singularnih vrijednosti su zanemarivo male i mogu se odbaciti bez uočljive promjene u kvaliteti slike. Konkretno u ovom primjeru, prva singularna vrijednost iznosi $4.75 \cdot 10^5$, singularne vrijednosti nakon 37. su reda 10^3, a nakon 309. su reda 10^2. Jasno je da relativno male singularne vrijednosti ne mogu značajno uticati na konačnu aproksimaciju. Grafik 4.10 prikazuje iznose prvih 50 singularnih vrijednosti.

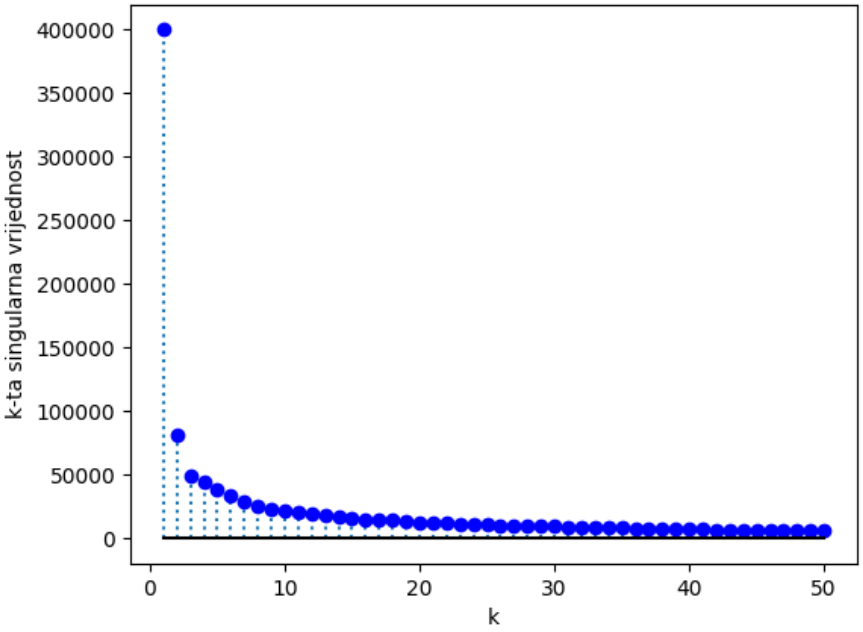

Slika 4.10: Singularne vrijednosti monohromatske slike

Na slici 4.11 je grafik kumulativne sume singularnih vrijednosti. Ovaj grafik pokazuje da je najveća količina informacija o slici sadržana u prvih otprilike 500 singularnih vrijednosti.

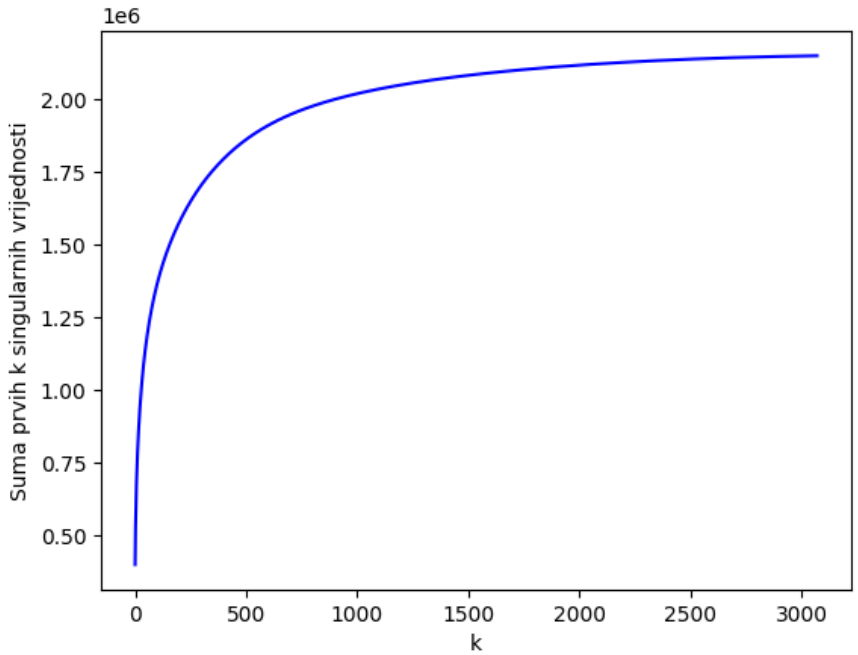

Slika 4.11: Kumulativna suma singularnih vrijednosti monohromatske slike

Još jedan dobar pokazatelj je i srednja kvadratna greška. Grafik 4.12 pokazuje da sa povećanjem broja korištenih singularnih vrijednosti od 1 do otprilike 500 greška naglo opada, a za veći broj korištenih singularnih vrijednosti je konstantno mala.

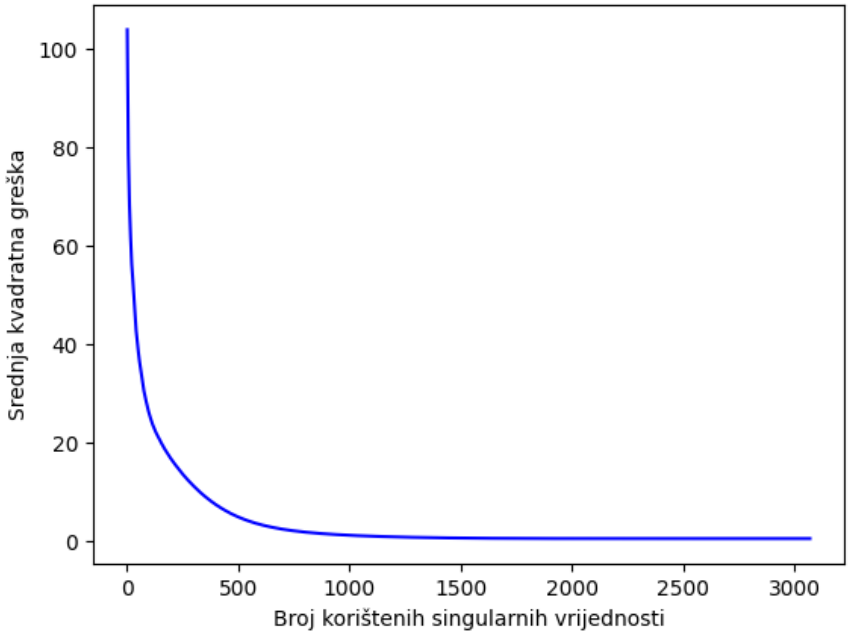

Slika 4.12: Srednja kvadratna greška za kompresovanu monohromatsku sliku

4.8 Primjer kompresije slike u boji

Ovdje će biti prikazana kompresija slike u boji, također BMP formata. Slika ima rezoluciju 3072 x 4608, pa je ukupan broj piksela 42 467 328. Zauzeće memorije je 42.5MB. U nastavku su rekonstruisane slike nastale korištenjem 1, 5, 10, 30, 100, 200, 1000 i 3072 (originalna slika) singularnih vrijdnosti.

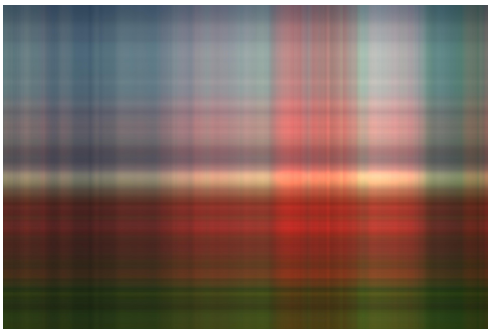

(a) $k = 1$

(b) $k = 5$

(c) $k = 10$

(d) $k = 30$

(e) $k = 100$

(f) $k = 200$

(g) $k = 1000$

(h) Originalna slika

Slika 4.13: Kompresija slike u boji korištenjem k singularnih vrijednosti

U tabeli 4.2 vidimo koliko je zauzeće memorije u odnosu na broj korištenih singularnih vrijednosti.

Tabela 4.2: Zauzeće memorije za kompresovanu sliku u boji

k	Zauzeće u B	Zauzeće u MB	Zauzeće u procentima
1	23 043	0.023	0.05%
5	115 215	0.12	0.27%
10	230 430	0.23	0.54%
30	691 290	0.69	1.63%
100	2 304 300	2.3	5.43%
200	4 608 600	4.6	10.85%
1000	23 043 000	23.04	54.26%

Slično kao i kod monohromatske slike, vidimo da slika nastala korištenjem 200 singularnih vrijednosti predstavlja odličnu aproksimaciju, a zauzima samo 10.85% memorijskog prostora u odnosu na originalnu sliku.

4.9 Zaključak

Vidjeli smo da se SVD može koristiti kao alat za kompresiju slike. Da bi se dobila kvalitetna kompresovana slika, ključan je izbor odgovarajuće vrijednosti za k (broj singularnih vrijednosti koje se koriste za kompresiju). Ta vrijednost treba biti dovoljno mala da bi se ostvarila ušteda memorije, a dovoljno velika da bi se zadržao kvalitet slike.

Potencijalno loša osobina ovog načina kompresije slike je duže izvršavanje algoritma za SVD faktorizaciju matrica velikih dimenzija.

* * *

U ovom poglavlju obrađena je redukcija dimenzionalnosti pomoću SVD i njena primjena na kompresiju slike. Dati su i konkretni primjeri kompresije slike.

Zaključak

SVD faktorizacija se u današnje vrijeme široko koristi u raznim oblastima procesiranja velikih skupova podataka, pogotovo kao alat za redukciju dimenzionalnosti u mašinskom učenju. Primjer kompresije slike pomoću SVD pomaže u razumijevanju ove faktorizacije i njenoj popularizaciji, a time i budućem razvoju algoritama koji će služiti za efikasno korištenje SVD-a u praksi.

Prilozi

Literatura

[1] Radošević Medvidović, I., Pedić, K., "Matrične faktorizacije", Zbornik radova (Građevinski fakultet Sveučilišta u Rijeci), Vol. 20, No. 1, 2017, str. 227–242.

[2] Brunton, S. L., Kutz, J. N., Data-driven science and engineering: Machine learning, dynamical systems, and control. Cambridge University Press, 2019.

[3] Stewart, G. W., "On the early history of the singular value decomposition", SIAM review, Vol. 35, No. 4, 1993, str. 551–566.

[4] Jurić, Ž., Numerički algoritmi. Elektrotehnički fakultet Univerziteta u Sarajevu, 2018.

[5] Chowning, S., "The singular value decomposition", 2020.

[6] Hogben, L., Handbook of linear algebra. CRC press, 2006.

[7] Bosner, N., "Fast methods for large scale singular value decomposition", Doktorska disertacija, University of Zagreb, Department of Mathematics, 2006.

[8] Zhang, W., Arvanitis, A., Al-Rasheed, A., "Singular value decomposition and its numerical computations", Michigan Technological University, Michigan, 2012.

[9] Golub, G. H., Van Loan, C. F., Matrix computations. JHU press, 2013, Vol. 3.

[10] Serrano, L. Singular value decomposition (svd) and image compression. YouTube, dostupno na: https://www.youtube.com/watch?v=DG7YTlGnCEo

[11] Swathi, H. R., Sohini, S., Surbhi, Gopichand, G., "Image compression using singular value decomposition", IOP Conference Series: Materials Science and Engineering, Vol. 263, nov 2017, str. 042082, dostupno na: https://doi.org/10.1088/1757-899x/263/4/042082

[12] Mathews, B., "Image compression using singular value decomposition (svd)", The University of Utah, 2014.

[13] NumPy, "numpy.linalg.svd", dostupno na: https://numpy.org/doc/stable/reference/generated/numpy.linalg.svd.html

[14] Mounika, K., Lakshmi, D. S. N., Alekya, K., "Svd based image compression", International journal of engineering research and general science, Vol. 3, No. 2, 2015, str. 1271–1278.