Zadatak 6 - Postoptimalna analiza

Promjena koeficijenata sa desne strane ograničenja

Bakir Činjarević 19705 & Amar Handanagić 19089

1 Postavka zadatka

Fabrika proizvodi 2 različita tipa radija. Jedini kritični resurs potreban za proizvodnju su radnici. Kompanija ima dva radnika. Radnik 1 može raditi maksimalno 40 sati tokom sedmice i plaćen je 5 KM po satu. Radnik 2 može raditi maksimalno 50 sati sedmično i plaćen je 6 KM po satu. Prodajna cijena i resursi potrebni za izradu svakog tipa radija dati su u tabeli ispod:

Proizvod	Radnik 1 (h)	Radnik 2 (h)	Cijena materijala (KM)	Prodajna cijena (KM)
Radio 1	1	2	5	25
Radio 2	2	1	4	22

Tablica 1: Podaci o proizvodnji radija

Simpleks tabela koja odgovara optimalnom rješenju ovog zadatka (cilj je maksimizacija dobiti) je:

Baza	b_i	X_1	X_2	X_3	X_4
X_2	10	0	1	$\frac{2}{3}$	$-\frac{1}{3}$
X_1	20	1	0	$-\frac{1}{3}$	$\frac{2}{3}$
Z	-80	0	0	$-\frac{1}{3}$	$-\frac{4}{3}$

Tablica 2: Optimalna simpleks tabela

2 Rješavanje zadatka

2.1 a) Matematički model i dualni problem

2.1.1 Primalni problem

Prvo je potrebno odrediti funkciju cilja. Dobit po radiju se računa kao:

$$\text{Dobit} = \text{Prodajna cijena} - \text{Cijena materijala} - \text{Cijena rada} \tag{1}$$

Za Radio 1:

$$\text{Dobit}_1 = 25 - 5 - (1 \cdot 5 + 2 \cdot 6) = 25 - 5 - 17 = 3 \text{ KM} \tag{2}$$

Za Radio 2:

$$\text{Dobit}_2 = 22 - 4 - (2 \cdot 5 + 1 \cdot 6) = 22 - 4 - 16 = 2 \text{ KM} \tag{3}$$

Neka su:

- x_1 = broj radija tipa 1
- x_2 = broj radija tipa 2

Matematički model primalnog problema:

$$\begin{aligned}
\max \quad & Z = 3x_1 + 2x_2 && (4)\\
\text{p.o.} \quad & x_1 + 2x_2 \leq 40 \quad \text{(ograničenje radnika 1)} && (5)\\
& 2x_1 + x_2 \leq 50 \quad \text{(ograničenje radnika 2)} && (6)\\
& x_1, x_2 \geq 0 && (7)
\end{aligned}$$

2.1.2 Dualni problem

Prema pravilima dualnosti, dualni problem glasi:

$$\begin{aligned}
\min \quad & W = 40y_1 + 50y_2 && (8)\\
\text{p.o.} \quad & y_1 + 2y_2 \geq 3 && (9)\\
& 2y_1 + y_2 \geq 2 && (10)\\
& y_1, y_2 \geq 0 && (11)
\end{aligned}$$

gdje su y_1 i y_2 dualne promjenljive koje odgovaraju ograničenjima radnika 1 i radnika 2.

2.2 b) Novo optimalno rješenje za $b_1' = 28$

Kada se koeficijent sa desne strane prvog ograničenja promijeni sa $b_1 = 40$ na $b_1' = 28$, potrebno je odrediti novo optimalno rješenje bez rješavanja problema ispočetka.

Iz optimalne simpleks tabele vidimo da su u optimalnom rješenju bazne varijable X_1 i X_2. Matrica A_B^{-1} se može očitati iz optimalne tabele u kolonama koje odgovaraju početnim slack varijablama (X_3 i X_4):

$$A_B^{-1} = \begin{bmatrix} \frac{2}{3} & -\frac{1}{3} \\ -\frac{1}{3} & \frac{2}{3} \end{bmatrix} \tag{12}$$

Novi vektor desnih strana je:

$$b' = \begin{bmatrix} 28 \\ 50 \end{bmatrix} \tag{13}$$

Novo bazno rješenje se računa po formuli:

$$x_B' = A_B^{-1} \cdot b' \tag{14}$$

$$x'_B = \begin{bmatrix} \frac{2}{3} & -\frac{1}{3} \\ -\frac{1}{3} & \frac{2}{3} \end{bmatrix} \begin{bmatrix} 28 \\ 50 \end{bmatrix} \tag{15}$$

$$= \begin{bmatrix} \frac{2}{3} \cdot 28 - \frac{1}{3} \cdot 50 \\ -\frac{1}{3} \cdot 28 + \frac{2}{3} \cdot 50 \end{bmatrix} \tag{16}$$

$$= \begin{bmatrix} \frac{56-50}{3} \\ \frac{-28+100}{3} \end{bmatrix} \tag{17}$$

$$= \begin{bmatrix} 2 \\ 24 \end{bmatrix} \tag{18}$$

Dakle, $x'_2 = 2$ i $x'_1 = 24$.

Provjeravamo dopustivost: $x'_B = [2, 24]^T \geq 0$, što znači da je rješenje dopustivo i optimalna baza se nije promijenila.

Nova vrijednost funkcije cilja se može izračunati na dva načina:

1. Direktno: $Z' = 3 \cdot 24 + 2 \cdot 2 = 72 + 4 = 76$ KM
2. Koristeći formulu iz optimalne tabele:

$$Z' = Z_0 + y_1 \cdot \Delta b_1 + y_2 \cdot \Delta b_2 \tag{19}$$

$$= 80 + \frac{1}{3} \cdot (28 - 40) + \frac{4}{3} \cdot (50 - 50) \tag{20}$$

$$= 80 + \frac{1}{3} \cdot (-12) + 0 \tag{21}$$

$$= 80 - 4 = 76 \text{ KM} \tag{22}$$

Napomena: U optimalnoj tabeli vrijednost $Z = -80$ je negativna jer je to zapisano u standardnom obliku simpleks metode. Stvarna vrijednost funkcije cilja je $Z = 80$ KM. Dualne vrijednosti $y_1 = \frac{1}{3}$ i $y_2 = \frac{4}{3}$ se čitaju iz optimalne tabele (apsolutne vrijednosti koeficijenata u redu Z za slack varijable).

2.3 c) Novo optimalno rješenje za $b'_1 = 102$

Sada promijenimo b_1 sa 40 na 102 sata. Novi vektor desnih strana je:

$$b' = \begin{bmatrix} 102 \\ 50 \end{bmatrix} \tag{23}$$

Računamo novo bazno rješenje:

$$x'_B = A_B^{-1} \cdot b' \tag{24}$$

$$= \begin{bmatrix} \frac{2}{3} & -\frac{1}{3} \\ -\frac{1}{3} & \frac{2}{3} \end{bmatrix} \begin{bmatrix} 102 \\ 50 \end{bmatrix} \tag{25}$$

$$= \begin{bmatrix} \frac{2}{3} \cdot 102 - \frac{1}{3} \cdot 50 \\ -\frac{1}{3} \cdot 102 + \frac{2}{3} \cdot 50 \end{bmatrix} \tag{26}$$

$$= \begin{bmatrix} \frac{204-50}{3} \\ \frac{-102+100}{3} \end{bmatrix} \tag{27}$$

$$= \begin{bmatrix} \frac{154}{3} \\ -\frac{2}{3} \end{bmatrix} \tag{28}$$

Dobijamo $x_2' = \frac{154}{3} \approx 51.33$ i $x_1' = -\frac{2}{3} < 0$.

Pošto je $x_1' < 0$, rješenje nije dopustivo. Optimalna baza se promijenila i potrebno je primijeniti dualni simpleks metod.

Prvo formiramo početnu tabelu sa novim vektorom desnih strana $b' = [102, 50]^T$. Nova vrijednost funkcije cilja se računa kao:

$$Z' = Z_0 + y_1 \cdot \Delta b_1 + y_2 \cdot \Delta b_2 \tag{29}$$

$$= -80 + \left(-\frac{1}{3}\right) \cdot (102 - 40) + \left(-\frac{4}{3}\right) \cdot (50 - 50) \tag{30}$$

$$= -80 - \frac{62}{3} = -\frac{302}{3} \tag{31}$$

Početna tabela (nedopustiva):

Baza	b_i	X_1	X_2	X_3	X_4
X_2	$\frac{154}{3}$	0	1	$\frac{2}{3}$	$-\frac{1}{3}$
X_1	$-\frac{2}{3}$	1	0	$-\frac{1}{3}$	$\frac{2}{3}$
Z	$-\frac{302}{3}$	0	0	$-\frac{1}{3}$	$-\frac{4}{3}$

Tablica 3: Početna tabela - nedopustivo rješenje

Primjenjujemo dualni simpleks metod:

Korak 1: Tabela je formirana. Svi koeficijenti u redu Z su negativni ili nule, što je uslov za primjenu dualnog simpleks metoda.

Korak 2: Provjeravamo da li su svi $b_i \geq 0$. Vidimo da je $b_2 = -\frac{2}{3} < 0$, pa prelazimo na korak 3.

Korak 3: Odabiremo red sa negativnim b_i. Red sa X_1 ima $b_i = -\frac{2}{3} < 0$, pa ga proglašavamo za vodeći red (red $p = 2$). Varijabla X_1 napušta bazu.

Korak 4: Provjeravamo da li su svi elementi vodećeg reda nenegativni. U redu X_1 imamo elemente: $[1, 0, -\frac{1}{3}, \frac{2}{3}]$. Element $-\frac{1}{3} < 0$ (u koloni X_3), pa problem ima dopustivo rješenje.

Korak 5: Za negativne elemente vodećeg reda formiramo količnike $\frac{c_j}{a_{p,j}}$:

- Za X_3: $\frac{-\frac{1}{3}}{-\frac{1}{3}} = 1$
- Za X_4: $\frac{-\frac{4}{3}}{\frac{2}{3}} = -2$ (ne uzimamo u obzir jer je $a_{p,j} > 0$)

Najmanji količnik je 1, što odgovara koloni X_3. Varijabla X_3 ulazi u bazu (kolona $q = 3$).

Korak 6: U bazi zamjenjujemo X_1 sa X_3.

Korak 7: Vršimo Gaussovu eliminaciju. Vodeći element je $a_{2,3} = -\frac{1}{3}$. Prvo množimo vodeći red sa -3 da dobijemo jedinicu na mjestu vodećeg elementa:

Baza	b_i	X_1	X_2	X_3	X_4
X_2	$\frac{154}{3}$	0	1	$\frac{2}{3}$	$-\frac{1}{3}$
X_3	2	-3	0	1	-2
Z	$-\frac{302}{3}$	0	0	$-\frac{1}{3}$	$-\frac{4}{3}$

Tablica 4: Nakon množenja vodećeg reda sa -3

Sada eliminišemo elemente u koloni X_3 iz ostalih redova. Prvo eliminišemo iz reda X_2:

$$\begin{aligned}
\text{Novi red } X_2 &= \text{Stari red } X_2 - \frac{2}{3} \cdot \text{Novi red } X_3 && (32)\\
&= \left[\frac{154}{3}, 0, 1, \frac{2}{3}, -\frac{1}{3}\right] - \frac{2}{3} \cdot [2, -3, 0, 1, -2] && (33)\\
&= \left[\frac{154}{3}, 0, 1, \frac{2}{3}, -\frac{1}{3}\right] - \left[\frac{4}{3}, -2, 0, \frac{2}{3}, -\frac{4}{3}\right] && (34)\\
&= [50, 2, 1, 0, 1] && (35)
\end{aligned}$$

Zatim eliminišemo iz reda Z:

$$\begin{aligned}
\text{Novi red } Z &= \text{Stari red } Z - \left(-\frac{1}{3}\right) \cdot \text{Novi red } X_3 && (36)\\
&= \left[-\frac{302}{3}, 0, 0, -\frac{1}{3}, -\frac{4}{3}\right] + \frac{1}{3} \cdot [2, -3, 0, 1, -2] && (37)\\
&= \left[-\frac{302}{3}, 0, 0, -\frac{1}{3}, -\frac{4}{3}\right] + \left[\frac{2}{3}, -1, 0, \frac{1}{3}, -\frac{2}{3}\right] && (38)\\
&= [-100, -1, 0, 0, -2] && (39)
\end{aligned}$$

Nova tabela nakon prve iteracije:

Baza	b_i	X_1	X_2	X_3	X_4
X_2	50	2	1	0	1
X_3	2	-3	0	1	-2
Z	-100	-1	0	0	-2

Tablica 5: Tabela nakon prve iteracije dualnog simpleks metoda

Korak 8: Vraćamo se na korak 2. Provjeravamo da li su svi $b_i \geq 0$:

- $b_1 = 50 \geq 0$
- $b_2 = 2 \geq 0$

Svi b_i su nenegativni, pa prelazimo na korak 9.
Korak 9: Optimalno rješenje je nađeno. Provjeravamo optimalnost:

- Svi $b_i \geq 0$ (rješenje je dopustivo)
- Svi koeficijenti u redu Z za nebazne varijable su negativni ili nule: $c_1 = -1 < 0$, $c_4 = -2 < 0$ (rješenje je optimalno)

Iz tabele očitavamo optimalne vrijednosti:

$$\begin{aligned}
&x_2 = 50 && (40)\\
&x_3 = 2 \quad \text{(slack varijabla za radnika 1)} && (41)\\
&x_1 = 0 \quad \text{(nebazna varijabla)} && (42)\\
&x_4 = 0 \quad \text{(nebazna varijabla, slack varijabla za radnika 2)} && (43)\\
&Z = -100 && (44)
\end{aligned}$$

Stvarna vrijednost funkcije cilja je $Z = 100$ KM (apsolutna vrijednost).
Dakle, novo optimalno rješenje je:

$$x_1' = 0 \tag{45}$$
$$x_2' = 50 \tag{46}$$
$$Z' = 100 \text{ KM} \tag{47}$$

2.4 d) Odgovori za rješenje pod c)

2.4.1 Koliko radija 1 i radija 2 treba proizvesti?

Iz optimalnog rješenja:

- Radio 1: $x_1 = 0$ jedinica
- Radio 2: $x_2 = 50$ jedinica

2.4.2 Koliko slobodnih sati će ostati na raspolaganju radniku 1 i radniku 2?

Slack varijable predstavljaju neiskorišćene resurse:

$$s_1 = 102 - (1 \cdot 0 + 2 \cdot 50) = 102 - 100 = 2 \text{ sata} \tag{48}$$
$$s_2 = 50 - (2 \cdot 0 + 1 \cdot 50) = 50 - 50 = 0 \text{ sati} \tag{49}$$

Dakle:

- Radnik 1 ima 2 slobodna sata
- Radnik 2 nema slobodnih sati (potpuno iskorišćen)

2.4.3 Da li su oba radija isplativa za proizvodnju?

Rentabilnost radija se određuje kroz odgovarajuće dualne promjenljive. U dualnom problemu:

- Prvo ograničenje: $y_1 + 2y_2 \geq 3$ odgovara Radio 1 (x_1)
- Drugo ograničenje: $2y_1 + y_2 \geq 2$ odgovara Radio 2 (x_2)

Prema teoremi komplementarne slackness, radio je rentabilan (tj. $x > 0$) ako i samo ako je odgovarajuće dualno ograničenje aktivno (tj. jednakost vrijedi, a ne striktna nejednakost). To znači da je odgovarajuća dualna slack varijabla jednaka nuli.

Iz optimalnog rješenja dualnog problema (iz nove optimalne tabele ili izračunato pomoću softvera):

- $y_1 = 0$ (ograničenje radnika 1 nije aktivno)
- $y_2 = 2$ (ograničenje radnika 2 je aktivno)

Provjeravamo aktivnost dualnih ograničenja:

- Za Radio 1: $y_1 + 2y_2 = 0 + 2 \cdot 2 = 4 > 3$. Ograničenje nije aktivno (slack > 0), što znači da Radio 1 **nije rentabilan** ($x_1 = 0$).
- Za Radio 2: $2y_1 + y_2 = 2 \cdot 0 + 2 = 2 = 2$. Ograničenje je aktivno (slack $= 0$), što znači da Radio 2 **je rentabilan** ($x_2 = 50 > 0$).

2.4.4 Koliko će se povećati vrijednost funkcije cilja pri jediničnom povećanju raspoloživih vremena radnika 1 i 2?

Ovo odgovara optimalnim vrijednostima dualnih promjenljivih (cijenama u sjeni). Iz optimalne simpleks tabele ili iz rješenja dualnog problema:

- Za radnika 1: $y_1 = \frac{1}{3}$ KM/sat (ili 0 ako je ograničenje neaktivno u novom rješenju)
- Za radnika 2: $y_2 = \frac{4}{3}$ KM/sat

U novom optimalnom rješenju (kada je $b_1 = 102$), dualne vrijednosti se mogu očitati iz nove optimalne tabele ili izračunati pomoću softvera. Iz rješenja dobijamo:

- Za radnika 1: $y_1 = 0$ KM/sat (ograničenje nije aktivno jer ima slobodnih sati)
- Za radnika 2: $y_2 = 2$ KM/sat (ograničenje je aktivno)

2.4.5 Koliko mora iznositi dobit po proizvedenom radiju da bi on postao isplativ?

Vrijednost koju radio mora imati da bi postao rentabilan se dobije preko spregnute dualne promjenljive za tu primalnu promjenljivu.

Za Radio 1, spregnuto dualno ograničenje je:

$$y_1 + 2y_2 \geq c_1 \tag{50}$$

gdje je c_1 dobit po radiju 1. Trenutno je $c_1 = 3$ KM.

Iz optimalnog rješenja dualnog problema imamo $y_1 = 0$ i $y_2 = 2$. Provjeravamo:

$$y_1 + 2y_2 = 0 + 2 \cdot 2 = 4 > 3 = c_1 \tag{51}$$

Pošto je $y_1 + 2y_2 > c_1$, dualno ograničenje nije aktivno, što znači da Radio 1 nije rentabilan.

Da bi Radio 1 postao rentabilan, potrebno je da dualno ograničenje postane aktivno, odnosno:

$$y_1 + 2y_2 = c_1' \tag{52}$$
$$4 = c_1' \tag{53}$$

Dakle, dobit po radiju 1 mora biti **jednaka 4 KM** da bi Radio 1 postao rentabilan (tj. da bi dualno ograničenje postalo aktivno i $x_1 > 0$).

Trenutna dobit je 3 KM, što je manje od potrebne vrijednosti 4 KM. Pošto je $y_1+2y_2 = 4 > 3 = c_1$, dualno ograničenje nije aktivno (slack > 0), što prema komplementarnoj slackness znači da je $x_1 = 0$ u optimalnom rješenju.

2.5 e) Provjera rješenja u Juliji

Rješenja pod b) i c) su provjerena pomoću JuMP paketa u programskom jeziku Julia. Rezultati se poklapaju sa teorijskim izračunima.

Za slučaj b) ($b_1 = 28$):

- Ulazni podaci: $b_1 = 28$, $b_2 = 50$, funkcija cilja: $\max Z = 3x_1 + 2x_2$

- Dobijeno rješenje: $x_1 = 24$, $x_2 = 2$, $Z = 76$ KM

Za slučaj c) ($b_1 = 102$):

- Ulazni podaci: $b_1 = 102$, $b_2 = 50$, funkcija cilja: $\max Z = 3x_1 + 2x_2$
- Dobijeno rješenje: $x_1 = 0$, $x_2 = 50$, $Z = 100$ KM

Detaljni kod i rezultati izvršavanja su dati u priloženom Julia fajlu.

3 Zaključak

Zadatak je demonstrirao primjenu postoptimalne analize za promjenu koeficijenata sa desne strane ograničenja. Kada je promjena dovoljno mala da optimalna baza ostane ista ($b_1 = 28$), novo rješenje se može direktno izračunati pomoću formule $x'_B = A_B^{-1} \cdot b'$. Kada promjena dovede do nedopustivog rješenja ($b_1 = 102$), potrebno je primijeniti dualni simpleks metod ili riješiti problem ispočetka.

4 Julia kod

Kompletan Julia kod za rješavanje zadatka:

```julia
# Zadatak 6 - Postoptimalna analiza (promjena koeficijenata sa desne strane ograni enja)
# Dualni simpleks metod

using JuMP
using GLPK
using LinearAlgebra

println("="^80)
println("ZADATAK 6 - POSTOPTIMALNA ANALIZA")
println("="^80)

# ==================== PODACI IZ ZADATKA ====================
# Radnik 1: max 40 sati, 5 KM/sat
# Radnik 2: max 50 sati, 6 KM/sat
# Radio 1: radnik 1 - 1h, radnik 2 - 2h, materijal 5 KM, prodajna cijena 25 KM
# Radio 2: radnik 1 - 2h, radnik 2 - 1h, materijal 4 KM, prodajna cijena 22 KM

# Funkcija cilja: maksimizacija dobiti
# Dobit po radiju = prodajna cijena - cijena materijala - cijena rada
# Radio 1: 25 - 5 - (1*5 + 2*6) = 25 - 5 - 17 = 3 KM
# Radio 2: 22 - 4 - (2*5 + 1*6) = 22 - 4 - 16 = 2 KM

# Varijable:
# x1 = broj radija tipa 1
# x2 = broj radija tipa 2
```

```julia

# Ograni enja:
# Radnik 1: 1*x1 + 2*x2 <= 40
# Radnik 2: 2*x1 + 1*x2 <= 50

# Funkcija cilja: max Z = 3*x1 + 2*x2

# Optimalna simpleks tabela:
# Baza | bi | X1 | X2 | X3 | X4
# X2   | 10 |  0 |  1 | 2/3| -1/3
# X1   | 20 |  1 |  0 | -1/3| 2/3
# Z    |-80 |  0 |  0 | -1/3| -4/3
# (X3 i X4 su slack varijable za radnika 1 i radnika 2)

# Matrica AB^(-1) se  ita  iz optimalne tabele u kolonama koje odgovaraju
# po etnim slack varijablama (X3 i X4):
# AB^(-1) = [2/3  -1/3]
#           [-1/3  2/3]

println("\n--- a) MATEMATI KI MODEL I DUALNI PROBLEM ---\n")

println("PRIMALNI PROBLEM:")
println("max Z = 3*x1 + 2*x2")
println("p.o.  x1 + 2*x2 <= 40   (radnik 1)")
println("      2*x1 + x2 <= 50   (radnik 2)")
println("      x1, x2 >= 0")

println("\nDUALNI PROBLEM:")
println("min W = 40*y1 + 50*y2")
println("p.o.  y1 + 2*y2 >= 3")
println("      2*y1 + y2 >= 2")
println("      y1, y2 >= 0")

# ==================== FUNKCIJA ZA RJE AVANJE POMO U JUMP ====================
function rijesi_lp(b1, b2; verbose=true)
    model = Model(GLPK.Optimizer)

    @variable(model, x1 >= 0)
    @variable(model, x2 >= 0)

    @objective(model, Max, 3*x1 + 2*x2)

    @constraint(model, radnik1, 1*x1 + 2*x2 <= b1)
    @constraint(model, radnik2, 2*x1 + 1*x2 <= b2)

    optimize!(model)

    if termination_status(model) == MOI.OPTIMAL
        x1_val = value(x1)
```

```
        x2_val = value(x2)
        Z_val = objective_value(model)

        # Provjera: Z mora biti jednako 3*x1 + 2*x2
        Z_provjera = 3*x1_val + 2*x2_val
        if abs(Z_val - Z_provjera) > 1e-6
            println("UPOZORENJE: Z ($Z_val) se ne poklapa sa 3*x1 + 2*x2 ($Z_provjera)")
        end

        # Dobijanje dualnih vrijednosti (cijene u sjeni)
        # JuMP vra a negativne vrijednosti za maksimizaciju, pa uzimamo apsolutnu vrijednost
        y1_val = abs(dual(radnik1))
        y2_val = abs(dual(radnik2))

        # Slack varijable
        slack1 = b1 - (1*x1_val + 2*x2_val)
        slack2 = b2 - (2*x1_val + 1*x2_val)

        if verbose
            println("\nOptimalno rje enje:")
            println("  x1 (Radio 1) = ", round(x1_val, digits=3))
            println("  x2 (Radio 2) = ", round(x2_val, digits=3))
            println("  Z (Dobit) = ", round(Z_val, digits=3), " KM")
            println("  Provjera: 3*x1 + 2*x2 = ", round(Z_provjera, digits=3), " KM")
            println("\nSlack varijable:")
            println("  Slobodni sati radnika 1 = ", round(slack1, digits=3))
            println("  Slobodni sati radnika 2 = ", round(slack2, digits=3))
            println("\nDualne varijable (cijene u sjeni):")
            println("  y1 (radnik 1) = ", round(y1_val, digits=3))
            println("  y2 (radnik 2) = ", round(y2_val, digits=3))
        end

        return x1_val, x2_val, Z_val, slack1, slack2, y1_val, y2_val
    else
        println("Rje enje nije prona eno! Status: ", termination_status(model))
        return nothing
    end
end

# ==================== FUNKCIJA ZA POSTOPTIMALNU ANALIZU ====================
```

```julia
function postoptimalna_analiza(b1_novo, b2_novo)
    # Matrica AB^(-1) iz optimalne tabele
    # Kolone X3 i X4 u optimalnoj tabeli daju AB^(-1)
    AB_inv = [2/3  -1/3;
              -1/3  2/3]

    # Novi vektor desnih strana
    b_novo = [b1_novo, b2_novo]

    # Izra unavanje novog baznog rje enja
    xB_novo = AB_inv * b_novo

    println("\nKori tenje formule xB' = AB^(-1) * b':")
    println("AB^(-1) = ")
    display(AB_inv)
    println("b' = ", b_novo)
    println("xB' = AB^(-1) * b' = ", round.(xB_novo, digits=3))

    # Provjera dopustivosti
    if all(xB_novo .>= 0)
        println("    Rje enje je dopustivo (xB' >= 0)")
        println("  Novo optimalno rje enje:")
        println("    x2 = ", round(xB_novo[1], digits=3))
        println("    x1 = ", round(xB_novo[2], digits=3))

        # Izra unavanje nove vrijednosti funkcije cilja
        # Iz optimalne tabele: Z = 80 + (1/3)*delta_b1 + (4/3)*delta_b2
        # gdje su delta_b razlike izme u novog i starog b
        b_staro = [40, 50]
        delta_b = b_novo - b_staro
        # Dualne vrijednosti iz optimalne tabele su -1/3 i -4/3, ali to je zbog na ina zapisa
        # Stvarna vrijednost funkcije cilja u optimalnoj tabeli je 80 (ne -80)
        delta_Z = (1/3)*delta_b[1] + (4/3)*delta_b[2]
        Z_novo = 80 + delta_Z

        println("    Z = ", round(Z_novo, digits=3), " KM")

        return true, xB_novo[2], xB_novo[1], Z_novo
    else
        println("    Rje enje NIJE dopustivo (neki elementi xB' < 0)")
        println("  Potrebno je primijeniti dualni simpleks metod")
        return false, nothing, nothing, nothing
    end
end

# ==================== DIJELOVI ZADATKA ====================
```

```
println("\n\n--- b) RADNIK 1 MO E RADITI MAKSIMALNO 28 SATI ---\n")
println("Originalno: b1 = 40, b2 = 50")
println("Novo: b1' = 28, b2' = 50")

b1_novo_b = 28
b2_novo_b = 50

dopustivo_b, x1_b, x2_b, Z_b = postoptimalna_analiza(b1_novo_b, b2_novo_b)

println("\nProvjera pomo u JuMP:")
x1_jump_b, x2_jump_b, Z_jump_b, slack1_b, slack2_b, y1_b, y2_b = rijesi_lp(b1_novo_b, b2_novo_b)

println("\n\n--- c) RADNIK 1 MO E RADITI MAKSIMALNO 102 SATA ---\n")
println("Originalno: b1 = 40, b2 = 50")
println("Novo: b1' = 102, b2' = 50")

b1_novo_c = 102
b2_novo_c = 50

dopustivo_c, x1_c, x2_c, Z_c = postoptimalna_analiza(b1_novo_c, b2_novo_c)

if !dopustivo_c
    println("\nRje enje nije dopustivo, rje avamo pomo u JuMP (dualni simpleks):")
end

println("\nProvjera pomo u JuMP:")
x1_jump_c, x2_jump_c, Z_jump_c, slack1_c, slack2_c, y1_c, y2_c = rijesi_lp(b1_novo_c, b2_novo_c)

println("\n\n--- d) ODGOVORI ZA RJE ENJE POD c) ---\n")
println("Koliko radija 1 i radija 2 treba proizvesti?")
println("  Radio 1: ", round(x1_jump_c, digits=3), " jedinica")
println("  Radio 2: ", round(x2_jump_c, digits=3), " jedinica")

println("\nKoliko slobodnih sati  e  ostati na raspolaganju radniku 1 i radniku 2?")
println("  Radnik 1: ", round(slack1_c, digits=3), " sati")
println("  Radnik 2: ", round(slack2_c, digits=3), " sati")

println("\nDa li su oba radija isplativa za proizvodnju?")
println("  Radio 1: ", x1_jump_c > 0 ? "DA (x1 > 0)" : "NE (x1 = 0)")
println("  Radio 2: ", x2_jump_c > 0 ? "DA (x2 > 0)" : "NE (x2 = 0)")
```

```
println("\nKoliko  e  se pove ati vrijednost funkcije cilja pri jedini nom pove anju raspolo ivih vremena radnika 1 i 2?")
println("  Radnik 1 (y1 - cijena u sjeni): ", round(y1_c, digits=3), " KM/sat")
println("  Radnik 2 (y2 - cijena u sjeni): ", round(y2_c, digits=3), " KM/sat")
println("  (Ovo zna i da bi pove anje kapaciteta radnika 1 za 1 sat pove alo dobit za ", round(y1_c, digits=3), " KM)")

println("\nUkoliko neki od radija nije isplativ za proizvodnju, koliko mora iznositi dobit po proizvedenom radiju da bi on postao isplativ?")
# Reducirane cijene iz optimalne tabele: -1/3 za X3, -4/3 za X4
# Ali ovo su za slack varijable. Za sami proizvod, trebamo provjeriti reduciranu cijenu.
# U optimalnoj tabeli, koeficijenti u redu Z za X1 i X2 su 0 (jer su bazne varijable).
# Reducirana cijena za neku varijablu pokazuje za koliko se funkcija cilja smanji pove anjem te varijable za 1.

# Ako je x1 > 0 i x2 > 0, oba su isplativa
if x1_jump_c > 0 && x2_jump_c > 0
    println("  Oba radija su isplativa za proizvodnju.")
else
    if x1_jump_c == 0
        println("  Radio 1 nije isplativ. Da bi postao isplativ, dobit po radiju 1 mora biti ve a.")
        println("  Trenutna dobit po radiju 1: 3 KM")
        println("  (Za ta nu vrijednost potrebno je izra unati reduciranu cijenu iz simpleks tabele)")
    end
    if x2_jump_c == 0
        println("  Radio 2 nije isplativ. Da bi postao isplativ, dobit po radiju 2 mora biti ve a.")
        println("  Trenutna dobit po radiju 2: 2 KM")
        println("  (Za ta nu vrijednost potrebno je izra unati reduciranu cijenu iz simpleks tabele)")
    end
end

println("\n\n--- e) PROVJERA RJE ENJA U JULIJI ---\n")

println("=== POD b) - Radnik 1: 28 sati ===")
println("Ulazni podaci:")
println("  b1 = ", b1_novo_b)
println("  b2 = ", b2_novo_b)
println("  Funkcija cilja: max Z = 3*x1 + 2*x2")
println("  Ograni enja: x1 + 2*x2 <= ", b1_novo_b, ", 2*x1 + x2 <= ", b2_novo_b)
x1_b, x2_b, Z_b, slack1_b, slack2_b, y1_b, y2_b = rijesi_lp(
```

```julia
    b1_novo_b, b2_novo_b)

println("\n=== POD c) - Radnik 1: 102 sata ===")
println("Ulazni podaci:")
println("  b1 = ", b1_novo_c)
println("  b2 = ", b2_novo_c)
println("  Funkcija cilja: max Z = 3*x1 + 2*x2")
println("  Ograni enja: x1 + 2*x2 <= ", b1_novo_c, ", 2*x1 + x2 <= ", b2_novo_c)
x1_c, x2_c, Z_c, slack1_c, slack2_c, y1_c, y2_c = rijesi_lp(b1_novo_c, b2_novo_c)

println("\n" * "="^80)
println("ZADATAK ZAVR EN")
println("="^80)
```

Listing 1: Julia kod za postoptimalnu analizu

```
=== POD b) - Radnik 1: 28 sati ===
Ulazni podaci:
  b1 = 28
  b2 = 50
  Funkcija cilja: max Z = 3*x1 + 2*x2
  Ograničenja: x1 + 2*x2 <= 28, 2*x1 + x2 <= 50

Optimalno rješenje:
  x1 (Radio 1) = 24.0
  x2 (Radio 2) = 2.0
  Z (Dobit) = 76.0 KM
  Provjera: 3*x1 + 2*x2 = 76.0 KM

Slack varijable:
  Slobodni sati radnika 1 = 0.0
  Slobodni sati radnika 2 = 0.0

Dualne varijable (cijene u sjeni):
  y1 (radnik 1) = 0.333
  y2 (radnik 2) = 1.333

=== POD c) - Radnik 1: 102 sata ===
Ulazni podaci:
  b1 = 102
  b2 = 50
  Funkcija cilja: max Z = 3*x1 + 2*x2
  Ograničenja: x1 + 2*x2 <= 102, 2*x1 + x2 <= 50

Optimalno rješenje:
  x1 (Radio 1) = 0.0
  x2 (Radio 2) = 50.0
  Z (Dobit) = 100.0 KM
  Provjera: 3*x1 + 2*x2 = 100.0 KM

Slack varijable:
  Slobodni sati radnika 1 = 2.0
  Slobodni sati radnika 2 = 0.0

Dualne varijable (cijene u sjeni):
  y1 (radnik 1) = 0.0
  y2 (radnik 2) = 2.0
```

Slika 1: Konzola